ANÁHUAC

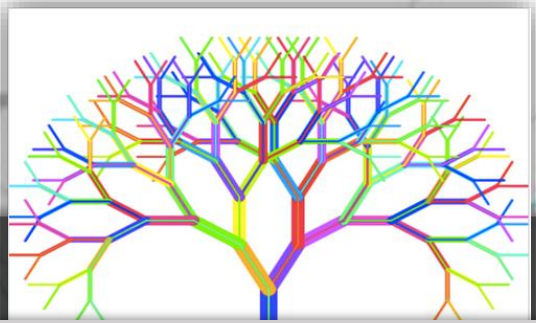

Árboles de Decisión

ANÁHUAC

Técnicas Machine Learning

Aprendizaje Supervisado

…

- Árboles Decisión
- SVM
- Vecinos más cercanos KNN
- Regresión Lineal
- Regresión Logística
- Redes Neuronales
- Bayes
- Discriminantes de Fisher
- …

ANÁHUAC

Árboles de Decisión

El objetivo es crear un modelo que clasifica o predice una variable de destino en función de diversas variables de entrada.

Árboles de Decisión

Variable Categórica

Variable Continua

Árboles de Clasificación

Árboles de Regresión

ANÁHUAC

Árbol de Clasificación

Un **árbol de clasificación** es un modelo de *machine learning supervisado* que **predice una clase (categoría)** tomando decisiones mediante una secuencia de **reglas tipo "si… entonces…"** sobre las variables de entrada, hasta llegar a una **hoja** que asigna la clase final.

ANÁHUAC

Árbol de Clasificación

Training Dataset

Color	Height	Label
Grey	10	Elephant
Yellow	10	Giraffe
Brown	3	Monkey
Grey	10	Elephant
Yellow	4	Tiger

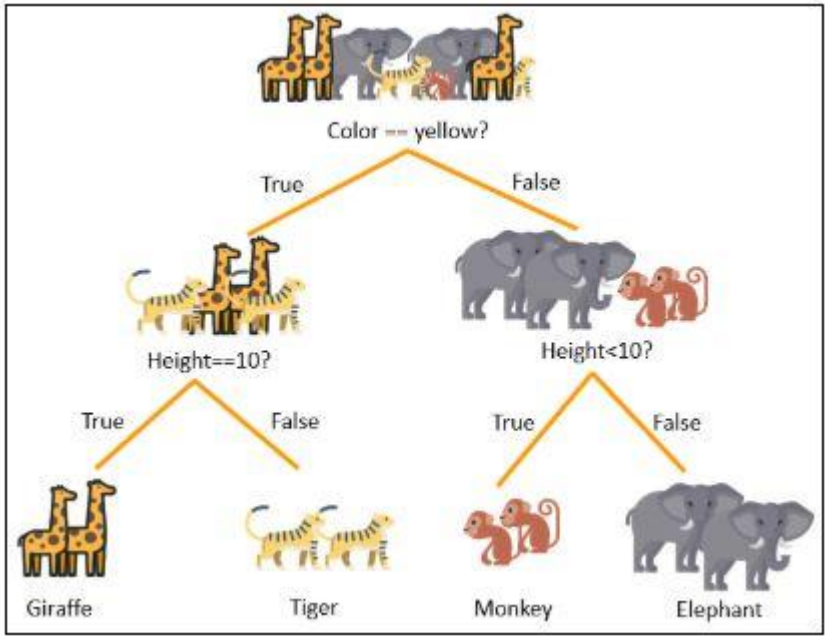

By SimpliLearn

Estructura de un árbol de clasificación

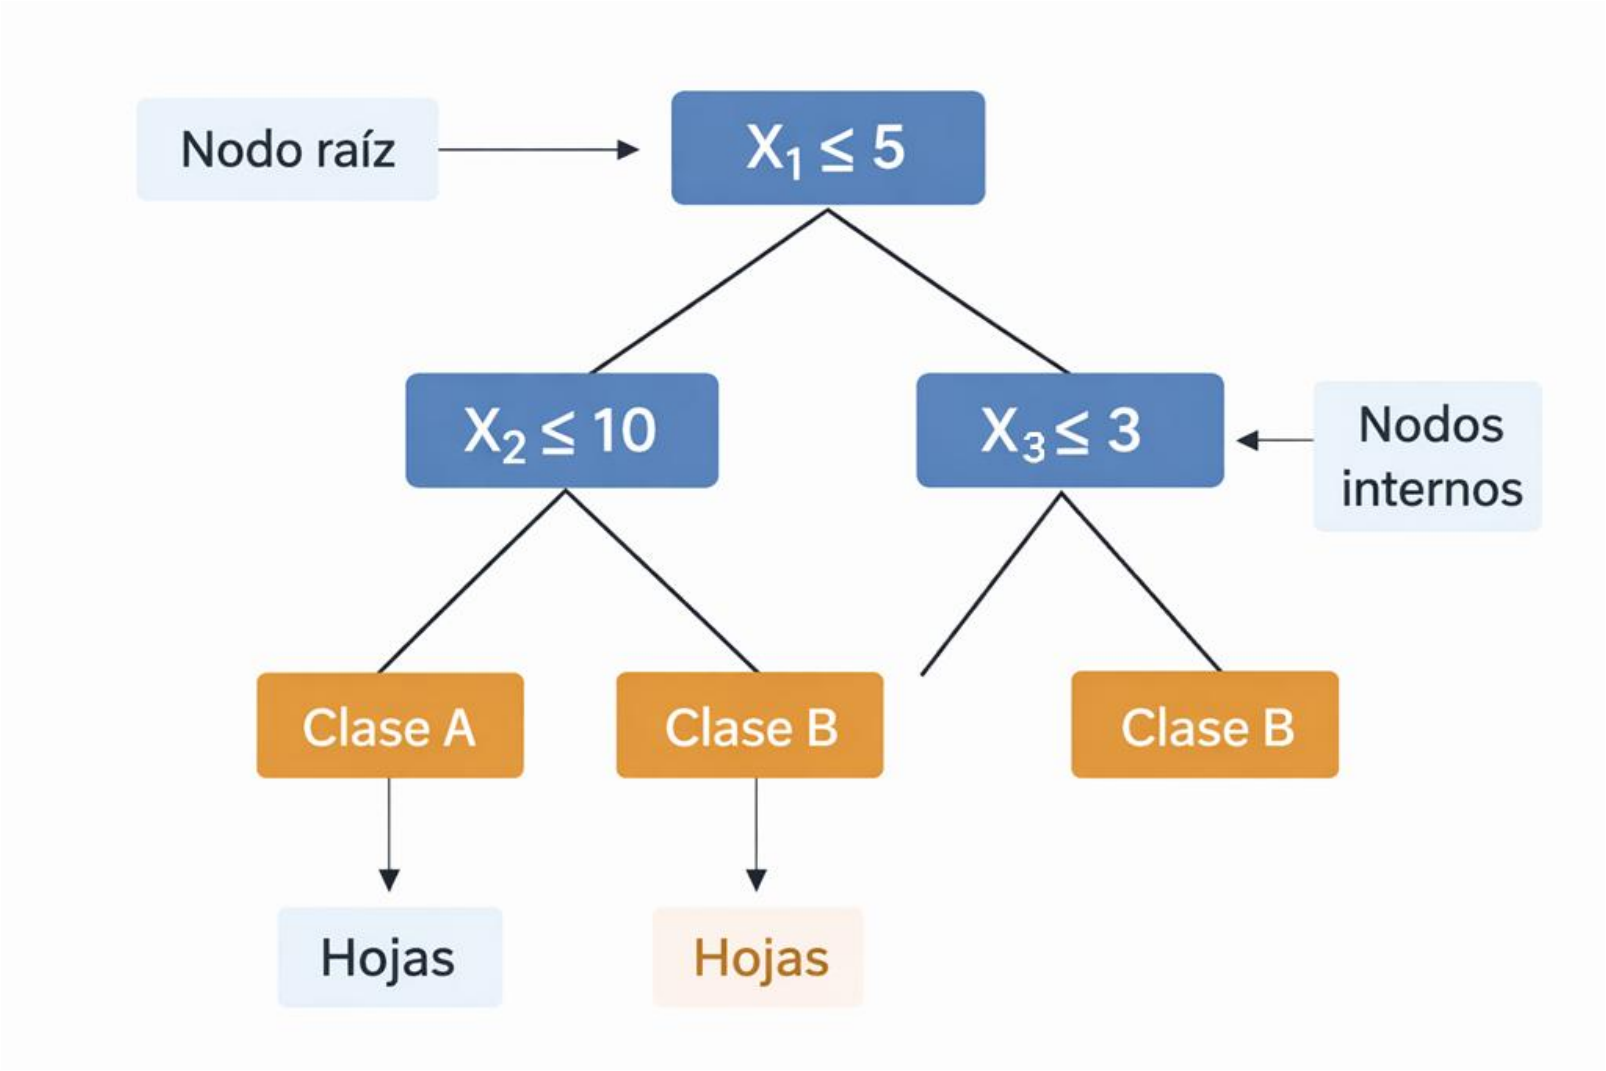

¿Cómo selecciona la mejor regla en cada nivel del árbol?

En cada nodo, el algoritmo:

1. **Prueba muchas reglas candidatas usando distintas características.**
2. **Evalúa cada regla** con un criterio de "calidad"
   La regla es mejor si deja los grupos resultantes **más "puros"** (menos mezclados en clases).
3. **Elige la regla que más reduce la impureza**
   1. Usando métricas como **Gini.**

$$\boxed{\text{Gini} = 1 - \sum_{i=1}^{K} p_i^2}$$

p_i = proporción de observaciones de la clase i en el nodo

K = número total de clases

Algoritmos comunes: ID3, C4.5, CART..

Si en un nodo hay:

- 60% clase A
- 40% clase B

$$\text{Gini} = 1 - (0.6^2 + 0.4^2) = 1 - (0.36 + 0.16) = 0.48$$

ANÁHUAC

¡Momento de ir a Programar!

ANÁHUAC

Matriz de Confusión

Accuracy (Exactitud):

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

		Clase predicha	
		Positiva	**Negativa**
Clase real	**Positiva**	TP	FN
	Negativa	FP	TN

Precision (Precisión): "¿Qué tan confiable es mi SÍ?"

$$\text{Precision} = \frac{TP}{TP + FP}$$

De todos los que el modelo dijo "Sí contrata", ¿cuántos de verdad contratan?

Recall (Sensibilidad): "¿Cuántos Sí reales logré encontrar?"

$$\text{Recall} = \frac{TP}{TP + FN}$$

De todos los que **sí contratan en la realidad**, ¿a cuántos detecté?

Overfitting en Árboles

Overfitting (sobreajuste) ocurre cuando un modelo:

Aprende "demasiado bien" los datos de entrenamiento, pero falla al generalizar a datos nuevos.

Los árboles son **muy propensos** al overfitting porque:

pueden seguir creciendo y crear reglas muy específicas creando hojas que representan **muy pocos datos.**

Overfitting en Árboles

Ejemplo de medidas para control de overfitting:

Limitar profundidad

max_depth=3 (profundidad de árbol)

Exigir más datos por nodo

min_samples_split=50, (min de datos que debe tener un nodo para dividirse)

min_samples_leaf=20 (min de datos que puede tener una hoja)