ANÁHUAC

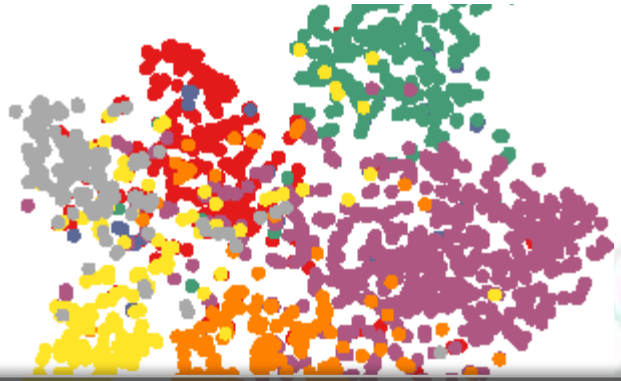

Clasificador Naive Bayes

ANÁHUAC

Técnicas Machine Learning

Aprendizaje Supervisado

…

- Árboles Decisión
- SVM
- Vecinos más cercanos KNN
- Regresión Lineal
- Regresión Logística
- Redes Neuronales
- Naive Bayes
- Discriminantes de Fisher
- …

Clasificador Naive Bayes

El **Naive Bayes** es un clasificador probabilístico que calcula qué tan probable es que un nuevo elemento pertenezca a una clase dado un conjunto de características.

Clasificador Naive Bayes

Variable Categórica

Problemas de Clasificación

ANÁHUAC

Clasificador Naive Bayes

El **Clasificador Naive Bayes** es un modelo probabilístico de clasificación supervisada basado en el **Teorema de Bayes**, el cual permite calcular la probabilidad posterior de una clase dado un conjunto de características observadas.

ANÁHUAC

Naive Bayes

$$P(A \mid B) = \frac{P(B \mid A)\, P(A)}{P(B)}$$

P(A|B) Es la probabilidad de que ocurra A dado que ya sabemos que ocurrió B.

Se le llama naive(ingenuo) porque asume que las características son independientes entre sí.

ANÁHUAC

Naive Bayes

$$P(C_k \mid X) = \frac{P(X \mid C_k)\, P(C_k)}{P(X)}$$

$P(C_k|X)$ Es la probabilidad de que el ejemplo pertenezca a la clase C_k dado sus características.

$P(X|C_k)$ → qué tan probable es observar esas características si la clase es C_k.

$P(C_k)$ → probabilidad previa de la clase.

$P(X)$ → probabilidad total de observar ese vector, es la misma en todas las clases. No se toma en cuenta

Naive Bayes

X1	X2	X3	Clase
1	1	1	A
1	1	0	A
1	0	1	A
0	1	1	A
1	0	0	A
0	0	0	B
0	0	1	B
0	1	0	B
1	0	0	B
0	1	0	B

Nuevo elemento a clasificar:
X1=1, X2=1, X3=0

$$P(A) = \frac{5}{10} = 0.5$$

$$P(X1 = 1 \mid A) = \frac{4}{5} = 0.8$$

$$P(X2 = 1 \mid A) = \frac{3}{5} = 0.6$$

$$P(X3 = 0 \mid A) = \frac{2}{5} = 0.4$$

Naive Bayes

X1	X2	X3	Clase
1	1	1	A
1	1	0	A
1	0	1	A
0	1	1	A
1	0	0	A
0	0	0	B
0	0	1	B
0	1	0	B
1	0	0	B
0	1	0	B

Nuevo elemento a clasificar:
X1=1, X2=1, X3=0

$$P(B) = \frac{5}{10} = 0.5$$

$$P(X1 = 1 \mid B) = \frac{1}{5} = 0.2$$

$$P(X2 = 1 \mid B) = \frac{2}{5} = 0.4$$

$$P(X3 = 0 \mid B) = \frac{4}{5} = 0.8$$

ANÁHUAC

Naive Bayes

Nuevo elemento a clasificar:
X1=1, X2=1, X3=0

$$\text{Score}(A) = P(A) \cdot P(X1 = 1 \mid A) \cdot P(X2 = 1 \mid A) \cdot P(X3 = 0 \mid A)$$

$$\text{Score}(A) = 0.5 \times 0.8 \times 0.6 \times 0.4$$

$$\boxed{\text{Score}(A) = 0.096}$$

$$\text{Score}(B) = P(B) \cdot P(X1 = 1 \mid B) \cdot P(X2 = 1 \mid B) \cdot P(X3 = 0 \mid B)$$

$$\text{Score}(B) = 0.5 \times 0.2 \times 0.4 \times 0.8$$

$$\boxed{\text{Score}(B) = 0.032}$$

$$0.096 > 0.032$$

Decisión Final: El nuevo elemento se clasifica como clase A.

ANÁHUAC

Familia de Bayes

👉 **GaussianNB ->** Variables predictoras continuas
👉 **MultinomialNB ->** Variables predictoras son frecuencias
👉 **BernoulliNB ->** Variables predictoras son binarias
👉 **CategoricalNB ->**Variables predictoras son categóricas con múltiples niveles (rojo, verde)

GaussianNB

$$\frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$

var_smoothing= 1e-9

$$\sigma^2 + \epsilon$$

[1e-9, 1e-8, 1e-7, 1e-6]

ANÁHUAC

¿Qué pasa si escalo los datos antes de hacer cross-validation?

👉 **Fuga de Datos** (**Data leakage)**. Si escalas usando todo el dataset, la información del test se filtra al train.

Usar un **pipeline** para asegurar que**:**
El escalado se calcula SOLO con el fold de entrenamiento y ese mismo escalado se aplica al fold de validación

Pipeline

Un Pipeline es una estructura que encapsula transformaciones y modelo como una sola unidad entrenable.

Un Pipeline asegura que los datos pasen por los mismos pasos de preparación antes de llegar al modelo, y que todo se entrene correctamente.

¿Qué valor de k uso en KNN?

¿Qué C uso en SVC?

¿Qué profundidad en árbol?

GridSearch

GridSearch

- Definir una cuadrícula de hiperparámetros.
- Evaluar todas las combinaciones.
- Usar validación cruzada para elegir la mejor.

Métricas Clasificación

Accuracy (Exactitud):

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

		Clase predicha	
		Positiva	**Negativa**
Clase real	**Positiva**	TP	FN
	Negativa	FP	TN

Precision (Precisión): "¿Qué tan confiable es mi SÍ?"

$$\text{Precision} = \frac{TP}{TP + FP}$$

De todos los que el modelo dijo "Sí contrata", ¿cuántos de verdad contratan?

Recall (Sensibilidad): "¿Cuántos Sí reales logré encontrar?"

$$\text{Recall} = \frac{TP}{TP + FN}$$

De todos los que **sí contratan en la realidad**, ¿a cuántos detecté?

Métricas Clasificación

F1 Balance entre precisión y recall: Solo es alto si **ambas** (precision y recall) son altas y penaliza cuando una es muy baja

$$\mathrm{F1} = 2 \cdot \frac{\mathrm{Precision} \cdot \mathrm{Recall}}{\mathrm{Precision} + \mathrm{Recall}}$$

Macro average: Calcula la métrica por clase y luego hace un promedio simple

$$\mathrm{Precision}_{macro} = \frac{1}{K} \sum_{k=1}^{K} \mathrm{Precision}_k$$

Weighted average: Calcula la métrica por clase y luego pondera según los datos por clase

$$\mathrm{Precision}_{weighted} = \sum_{k=1}^{K} \frac{n_k}{N} \cdot \mathrm{Precision}_k$$

n_k = support de la clase k

N = total de muestras

ANÁHUAC

Métricas

Situación	Métrica recomendada
Clases balanceadas	Accuracy
Clases desbalanceadas	F1
No perder positivos	Recall
Evitar falsas alarmas	Precisión
Evaluación general	F1

Buenas prácticas

- Dividir en train-test
- Pipeline
- Validación cruzada usando solo train
- Gridsearch
- Usar métricas adecuadas y evaluar con test externo

ANÁHUAC

¡Momento de ir a Programar!