ANÁHUAC PUEBLA

Asignatura:_Machine Learning

Algoritmos de agrupamiento: K-Means

Presentado por:

Paulo Daniel Vázquez Mora

Objetivo general

Propósito(s):

- Comprender la motivación del agrupamiento clustering, su formulación teórica y práctica de ***K-Means***.
- Capacidad de diseñar ejecutar y evaluar experimentos en conjuntos de datos.

Competencia(s):

- Elegir de manera efectiva el número de ***K.***
- Reconocer las limitaciones del método y la consideración de alternativas.

Resultado(s):

- Libreta con evidencia experimental.

ANÁHUAC PUEBLA

Introducción

El agrupamiento o ***clustering*** es la tarea de identificar subgrupos naturales (clusters) en conjuntos de datos no etiquetados.

Comúnmente son utilizados en:

- Exploración y detección de patrones.
- Segmentación por ejemplo, usuarios o clientes.
- Preprocesamiento para otras tareas generación de características.

ANÁHUAC PUEBLA

Aplicaciones del agrupamiento

Los algoritmos de agrupamiento tienen una amplia gama de aplicaciones en diversos campos, incluyendo:

Marketing
Segmentación de clientes para campañas de marketing personalizadas.

Medicina
Agrupamiento de pacientes basado en datos de historias clínicas para la detección temprana de enfermedades.

Análisis de Imágenes
Agrupamiento de píxeles para la segmentación de imágenes médicas o la identificación de objetos en fotografías.

Análisis de redes sociales
Identificación de comunidades o grupos de usuarios con intereses similares en redes sociales.

Procesamiento de Lenguaje Natural:
Agrupamiento de documentos de texto para la organización y clasificación de información.

ANÁHUAC PUEBLA

Conceptos básicos

La **distancia euclidiana** es una medida de distancia entre dos puntos en un espacio euclidiano (espacio geométrico donde se satisfacen los axiomas de la geometría de Euclides). Se calcula como la longitud del segmento de línea recta que une dos puntos.

Diversos algoritmos de clustering utilizan **funciones de similitud** basadas en esta medida (métrica).

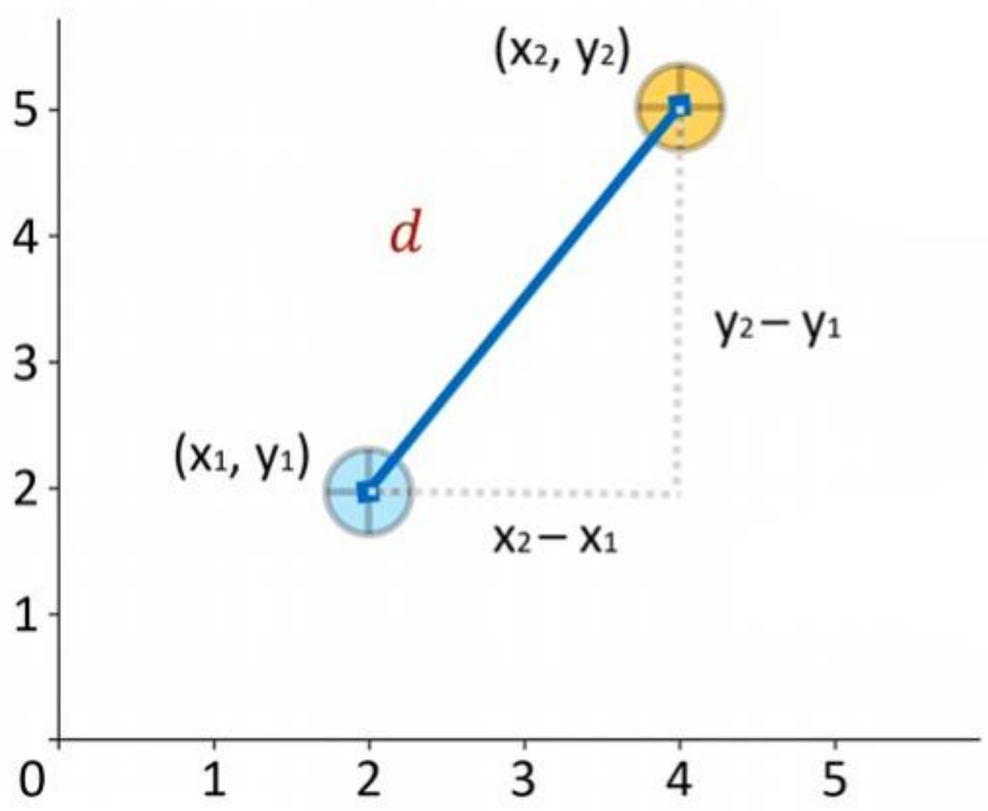

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

ANÁHUAC PUEBLA

Conceptos básicos

En el contexto del clustering, un **centroide** es el punto representativo de un cluster calculado a partir del promedio de todos los puntos en éste.

Es común utilizar centroides en algoritmos como K-Means para definir tanto la ubicación de un cluster como los elementos agrupados en él.

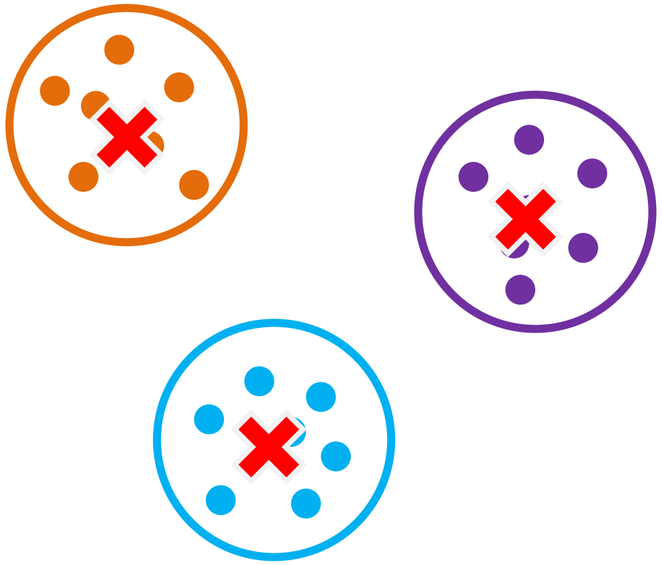

ANÁHUAC PUEBLA

Familias de algoritmos de clustering

Dentro de la clasificación de algoritmos de agrupamiento o clustering tenemos las siguientes familias:

- **Particional** donde se divide en K grupos, por ejemplo **K-Means**.
- Basado en **densidad** donde se identifican regiones densas y se separa el ruido, por ejemplo DBSCAN y Mean-Shift.
- **Difuso** donde se establece una pertenencia parcial a clusters, por ejemplo Fuzzy C-Means
- **Jerárquico** de agrupamientos Aglomerativo y divisivo.

Cada familia tiene supuestos distintos sobre la forma del ruido y la similitud.

ANÁHUAC PUEBLA

K-Means: Idea principal y función objetivo

ANÁHUAC PUEBLA

La idea principal del algoritmo es particionar ***N*** puntos en ***K*** clusters minimizando la suma de distancias cuadradas al centroide del cluster. Donde un centroide es la media de los puntos asignados al cluster. La función objetivo de K-Means (costo - inercia) se expresa a continuación:

$$J = \sum_{i=1}^{K} \sum_{x \in C_i} |x - \mu_i|^2$$

Donde:

- C_i son las particiones o clusters.
- μ_i es el centroide del cluster i (media de los puntos en C_i).
- x es un punto dentro del cluster i.
- $|x - \mu_i|$ es la distancia euclidiana.

K-Means: Idea principal y función objetivo

El valor descrito por J se puede interpretar de la siguiente manera:

- J pequeño – indica que los puntos son cercanos a sus centroides y por lo tanto es una buena agrupación.
- J grande – indica que los puntos están alejados de sus centroides y por lo tanto es una agrupación deficiente.

ANÁHUAC PUEBLA

K-Means: prerequisitos

Antes de evaluar un conjunto de datos con el algoritmo K-Means es necesario tener en cuenta lo siguiente:

- **Escalado:** Proceso de estandarización o normalización cuando las características tienen escalas distintas.
- **Manejo de outliers (valores atípicos):** Estos valores pueden sesgar los centroides, se recomienda usar técnicas de mitigación (clipping, winsorizing o usar algoritmos resistentes).
- **Reducción de dimensionalidad:** Se recomienda para proyectar a 2D/3D y visualizar clusters.
- **Codificación:** Las variables categóricas requieren transformación adecuada (one-hot, embeddings) antes de aplicar K-Means.

ANÁHUAC PUEBLA

K-Means: Pasos del algoritmo

ANÁHUAC PUEBLA

I. Inicialización

- Selección de K centroides al azar.

II. Selección de clusters

- Asignación de cada punto al centroide mas cercano.

III. Actualización

- Recalculo de los centroides con base en el promedio de los puntos del cluster.

IV. Iteraciones

- Repetición de la asignación y recalculo de centroides hasta cumplir un número de iteraciones o la convergencia de los mismos.

I. Inicialización

La selección inicial de centroides puede afectar los resultados del agrupamiento. Diferentes métodos de inicialización pueden conducir a resultados diferentes. Algunas técnicas comunes incluyen la inicialización aleatoria, la inicialización basada en heurísticas y la inicialización inteligente utilizando técnicas como KMeans++ (elige centroides con probabilidad proporcional a la distancia cuadrada a centroides ya seleccionados).

ANÁHUAC PUEBLA

II. Selección de clusters

Determinar el número óptimo de clusters (K) es crucial para obtener resultados significativos. Se pueden utilizar dos tipos de métodos:

Heurísticos

- Elbow method
- Silhouette score
- Gap Statistic
- Consideraciones del negocio

Prácticos

- Medición de inercias

ANÁHUAC PUEBLA

II. Selección de clusters

- Métodos heurísticos:
  - **Método del codo (Elbow):** Consiste en graficar la inercia (suma de distancias cuadradas dentro del cluster) vs. K en búsqueda del punto de inflexión aunque no siempre claro.
  - **Silhouette score:** Mide cuán bien separados están los clusters, es decir, si el puntaje promedio por muestra varía entre -1 y 1. Cuando los valores son cercanos a 1, eso indica que hay una buena separación.
  - **Gap Statistic:** Compara la inercia observada con la esperada bajo un modelo nulo, esta técnica es más robusta pero más costosa.
  - **Consideraciones de negocio:** La facilidad de interpretación y su utilidad práctica pueden dictar el valor de K, es decir, hallar un balance entre granularidad y acción.
- Evaluación práctica (experimental): Ejecutar varios K para conformar una tabla con las inercias obtenidas basándose en cualquiera de los métodos heurísticos.

ANÁHUAC PUEBLA

III. Actualización

Para cada cluster i el nuevo centroide μ_i es la media de los puntos asignados:

$$\mu_i = \frac{1}{|C_i|} \sum_{x \in C_i} x$$

Esta actualización busca minimizar localmente la suma de cuadrados dentro del cluster reduciendo la inercia.

ANÁHUAC PUEBLA

IV. Iteraciones

Como ya se ha establecido previamente, este algoritmo busca la convergencia de los centroides para lo cual se establecen algunos criterios de paro:

- La no existencia cambios en la asignación de puntos entre iteraciones.
- Cambios poco significativos en la función objetivo (inercia).
- Alcanzar un número máximo de iteraciones (épocas).
- Desplazamiento máximo de centroides menor que una tolerancia ε

ANÁHUAC PUEBLA

K-Means: Limitaciones

- Sensible a escalas y outliers.
- Incapacidad para detectar clusters de forma arbitraria (p. ej. anillos o lunas).
- Requiere K predefinido.
- Sensible al cambio de métricas de similitud (Chebyshev, Manhattan).

K-Means: Ejemplo (práctico)

Un banco desea realizar una segmentación de clientes para agruparlos considerando sus montos de compra y el número de operaciones realizadas con tarjeta de crédito en un año. Los datos se grafican a continuación:

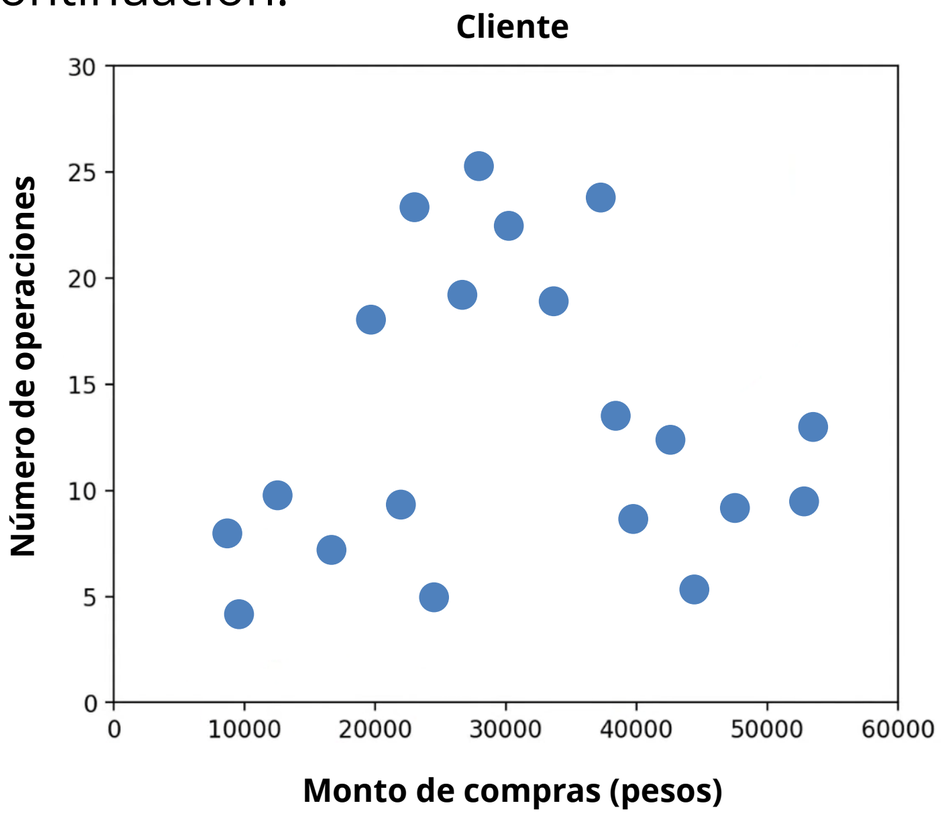

ANÁHUAC PUEBLA

K-Means: Ejemplo (práctico)

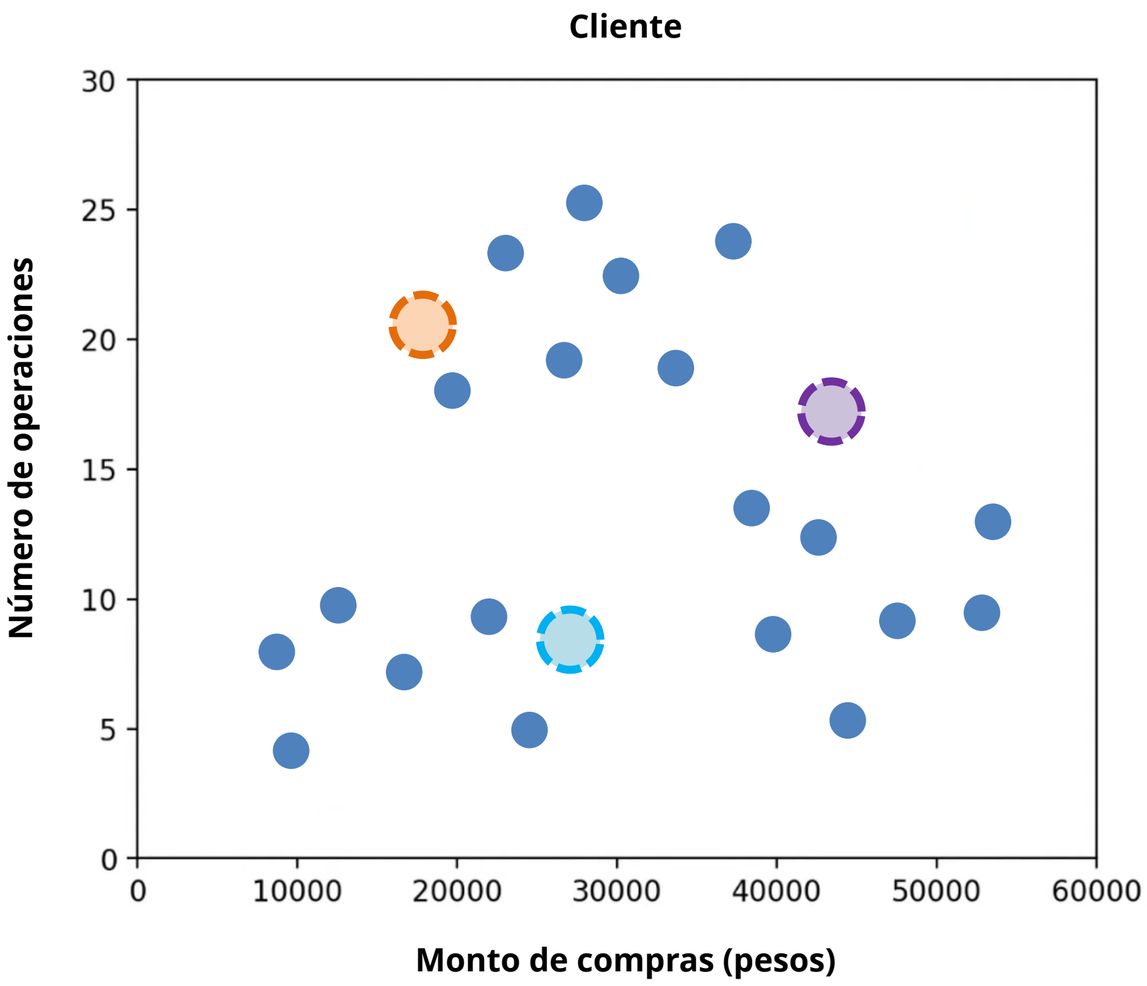

Etapa: Inicialización
K = 3
Iteración = 1

ANÁHUAC PUEBLA

K-Means: Ejemplo (práctico)

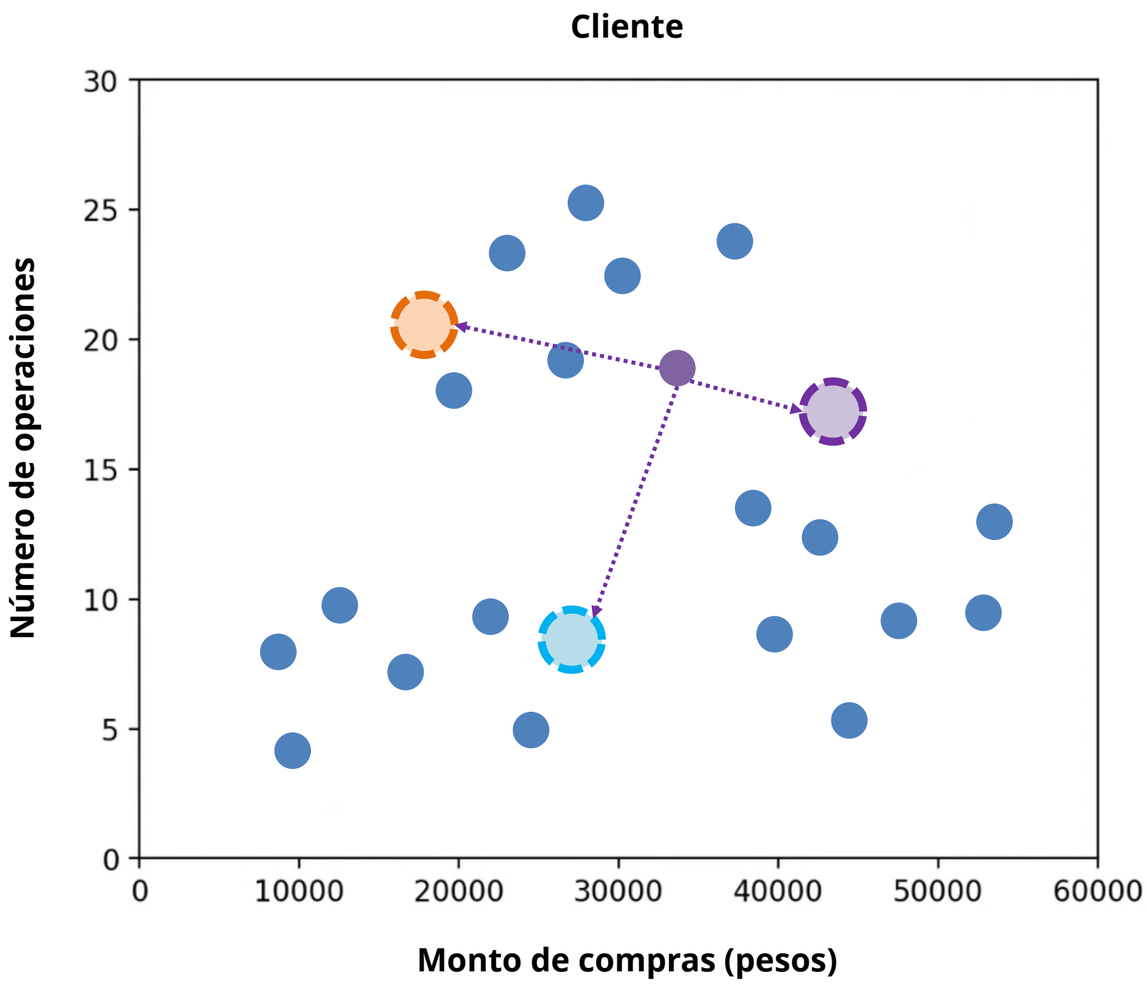

Etapa: Asignación
K = 3
Iteración = 1

ANÁHUAC PUEBLA

K-Means: Ejemplo (práctico)

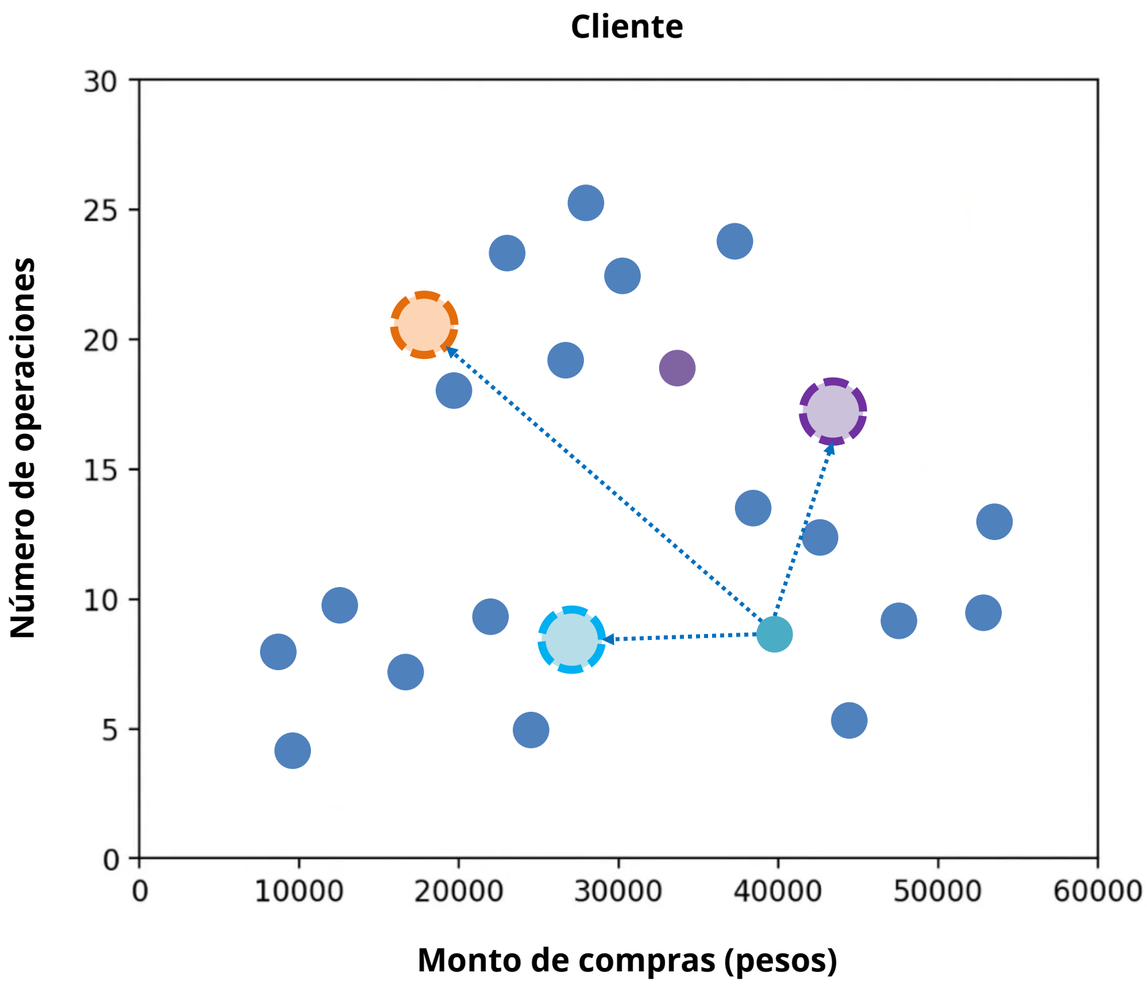

Etapa: Asignación
K = 3
Iteración = 1

ANÁHUAC PUEBLA

K-Means: Ejemplo (práctico)

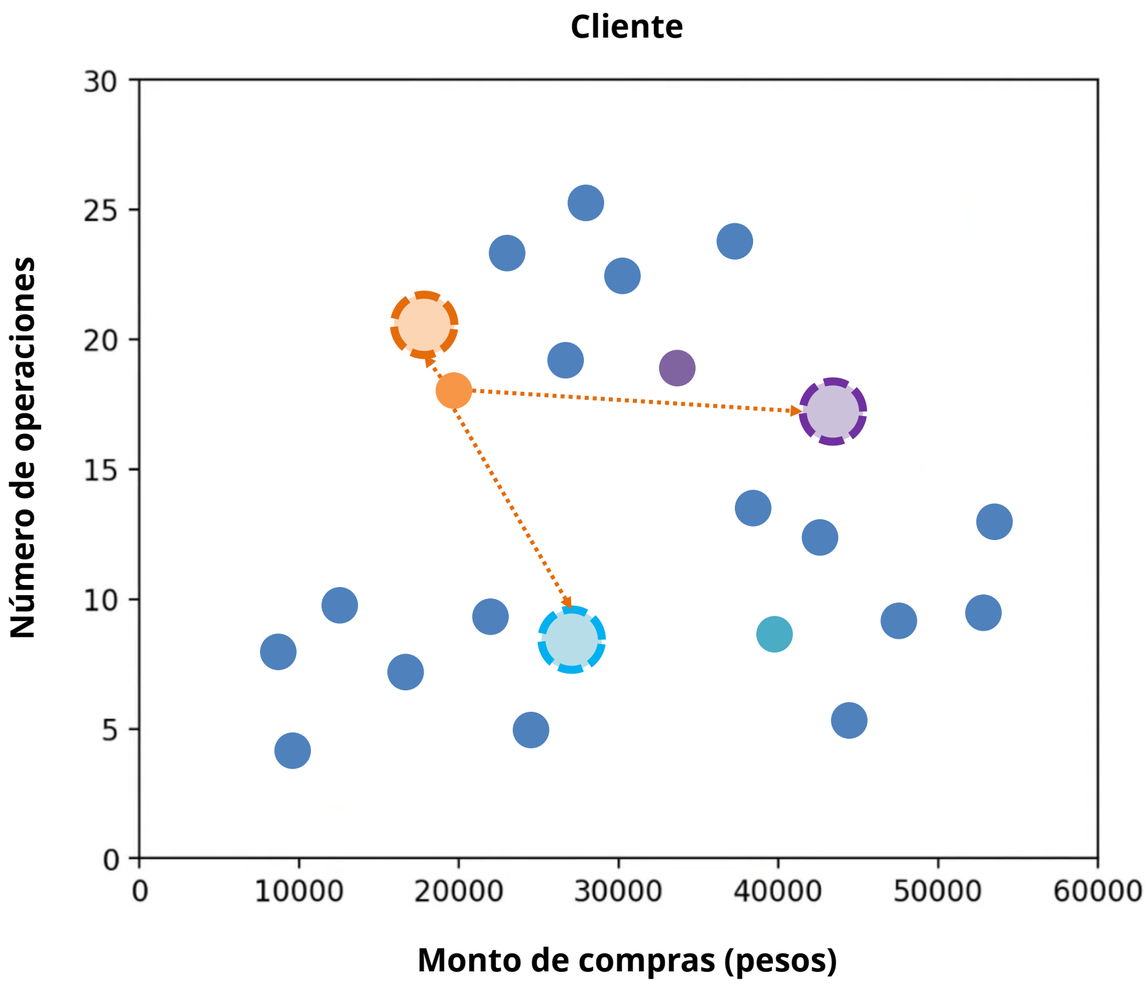

Etapa: Asignación
K = 3
Iteración = 1

ANÁHUAC PUEBLA

K-Means: Ejemplo (práctico)

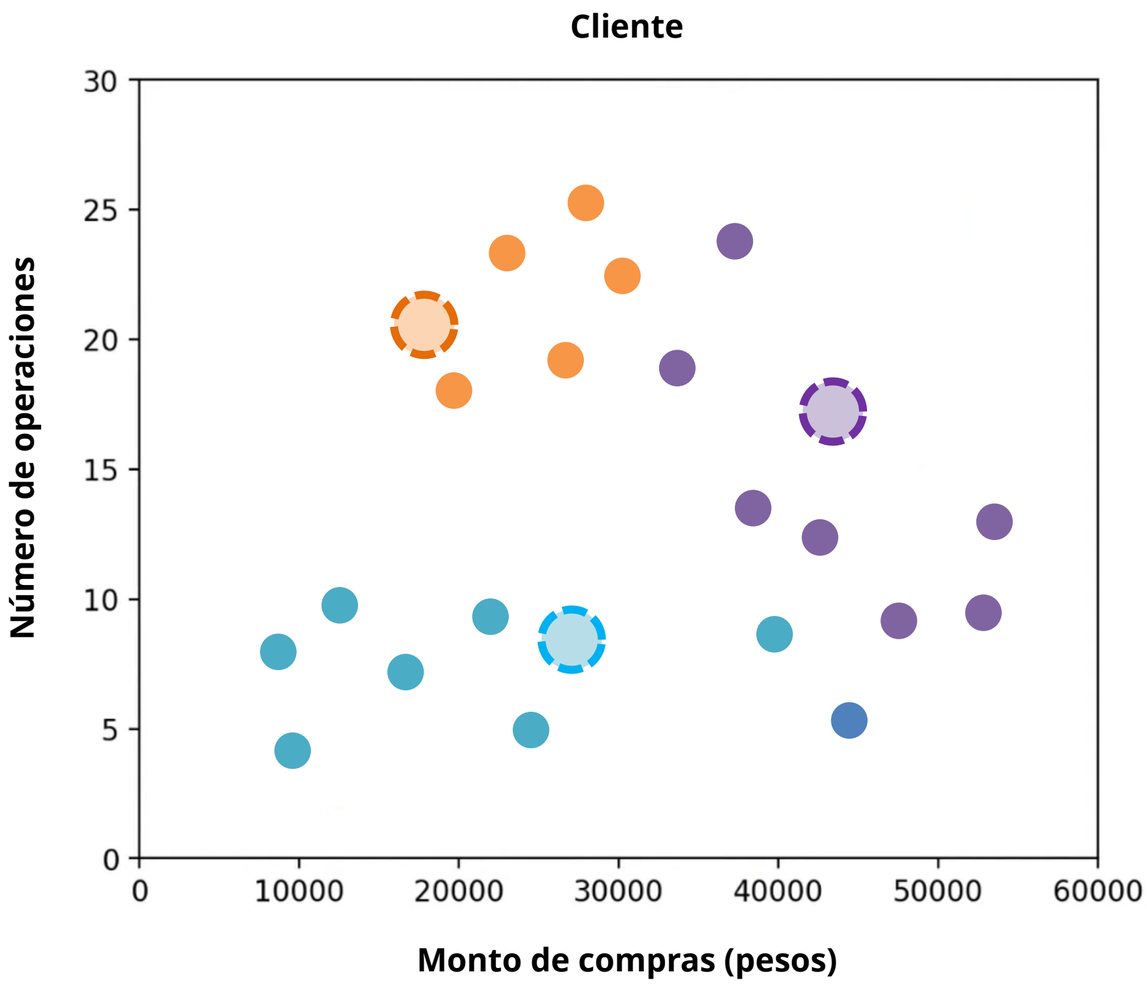

Etapa: Asignación
K = 3
Iteración = 1

ANÁHUAC PUEBLA

K-Means: Ejemplo (práctico)

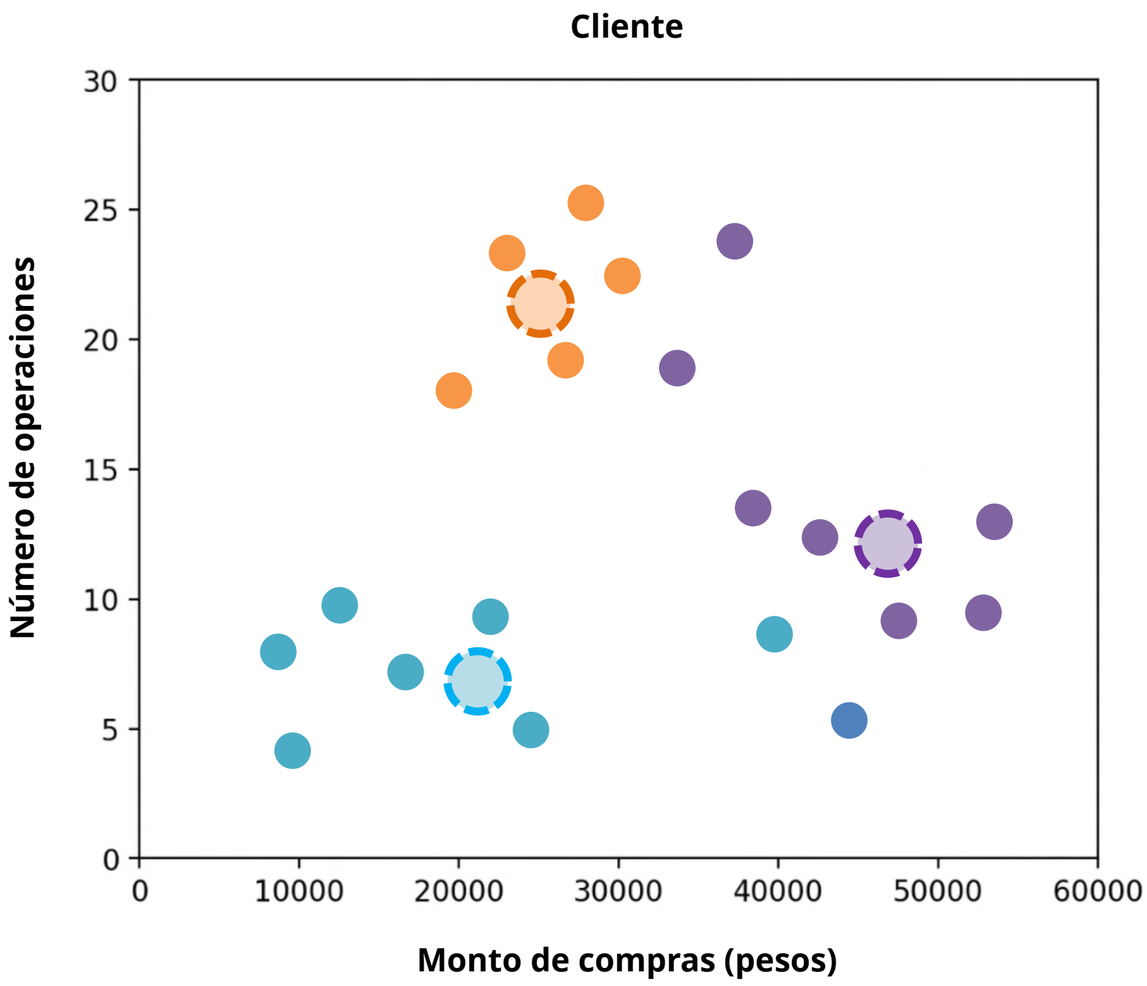

Etapa: Actualización
K = 3
Iteración = 1

ANÁHUAC PUEBLA

K-Means: Ejemplo (práctico)

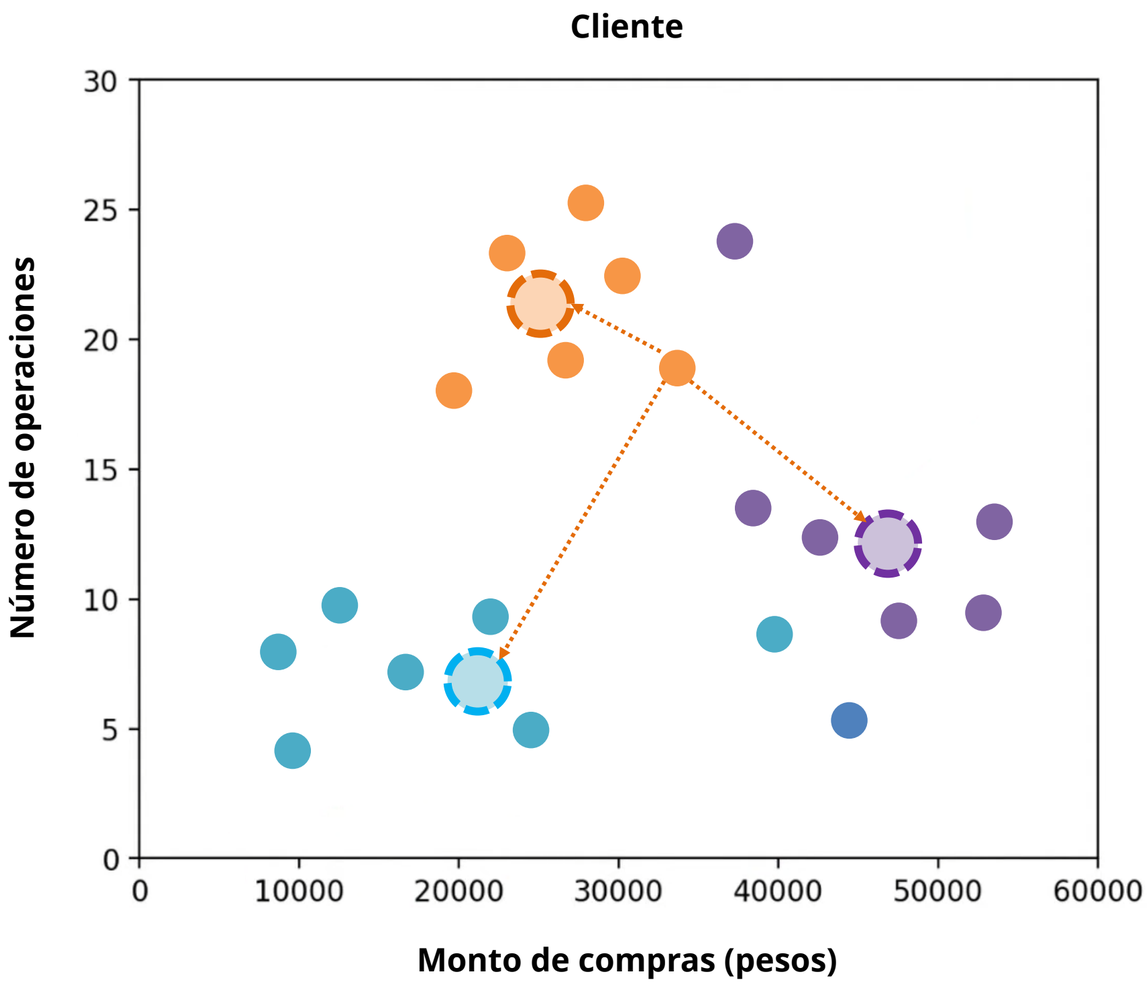

Etapa: Selección
K = 3
Iteración = 2

ANÁHUAC PUEBLA

K-Means: Ejemplo (práctico)

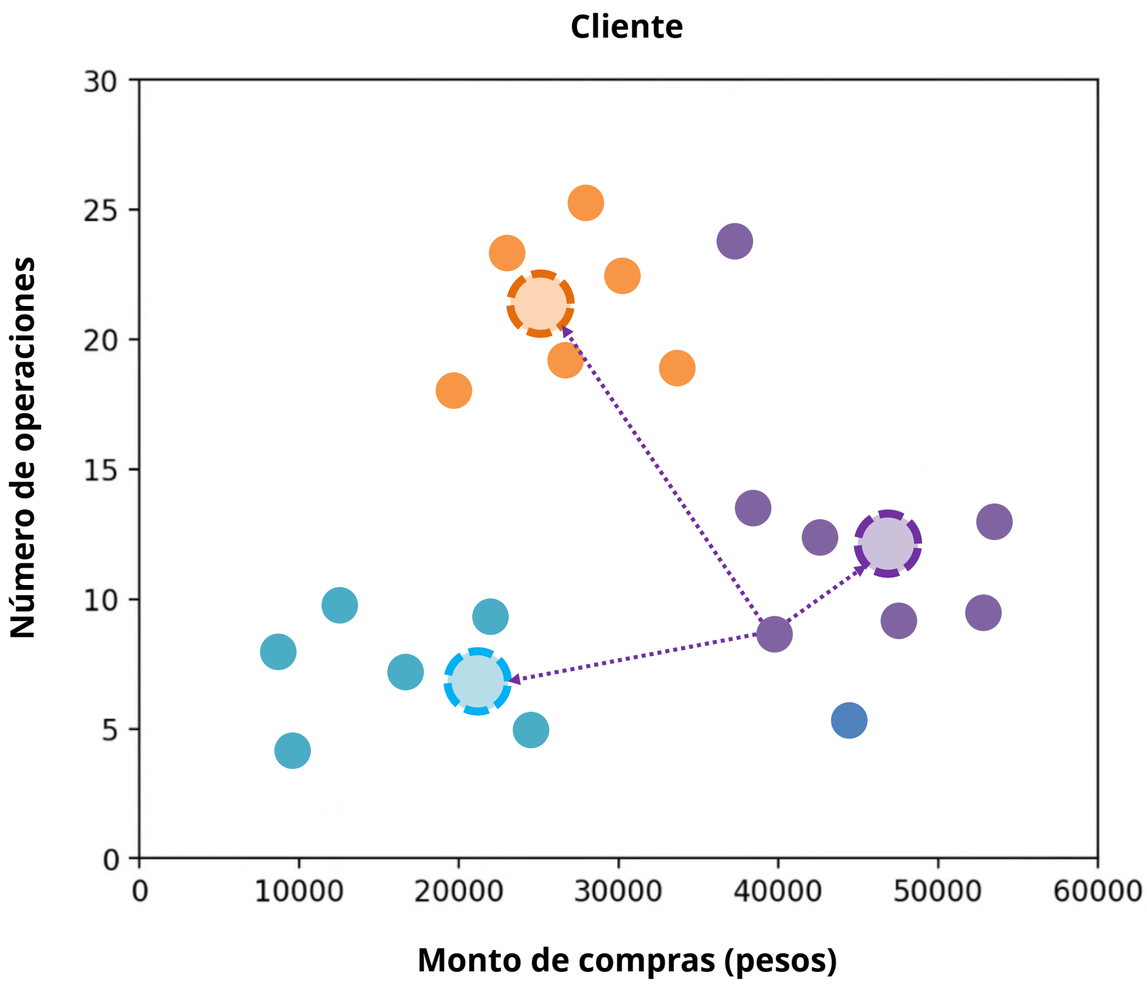

Etapa: Selección
K = 3
Iteración = 2

ANÁHUAC PUEBLA

K-Means: Ejemplo (práctico)

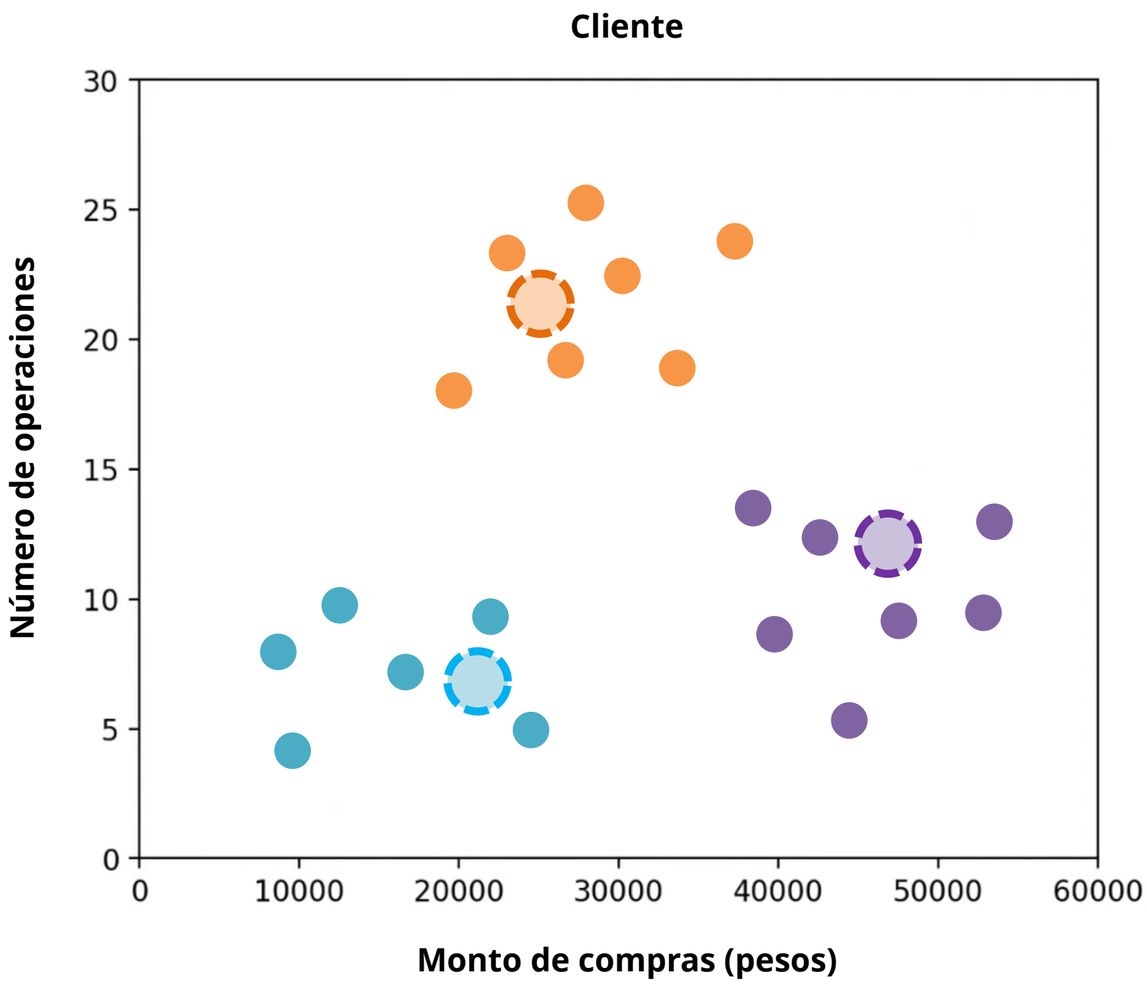

Etapa: Selección
K = 3
Iteración = 2

ANÁHUAC PUEBLA

K-Means: Ejemplo (práctico)

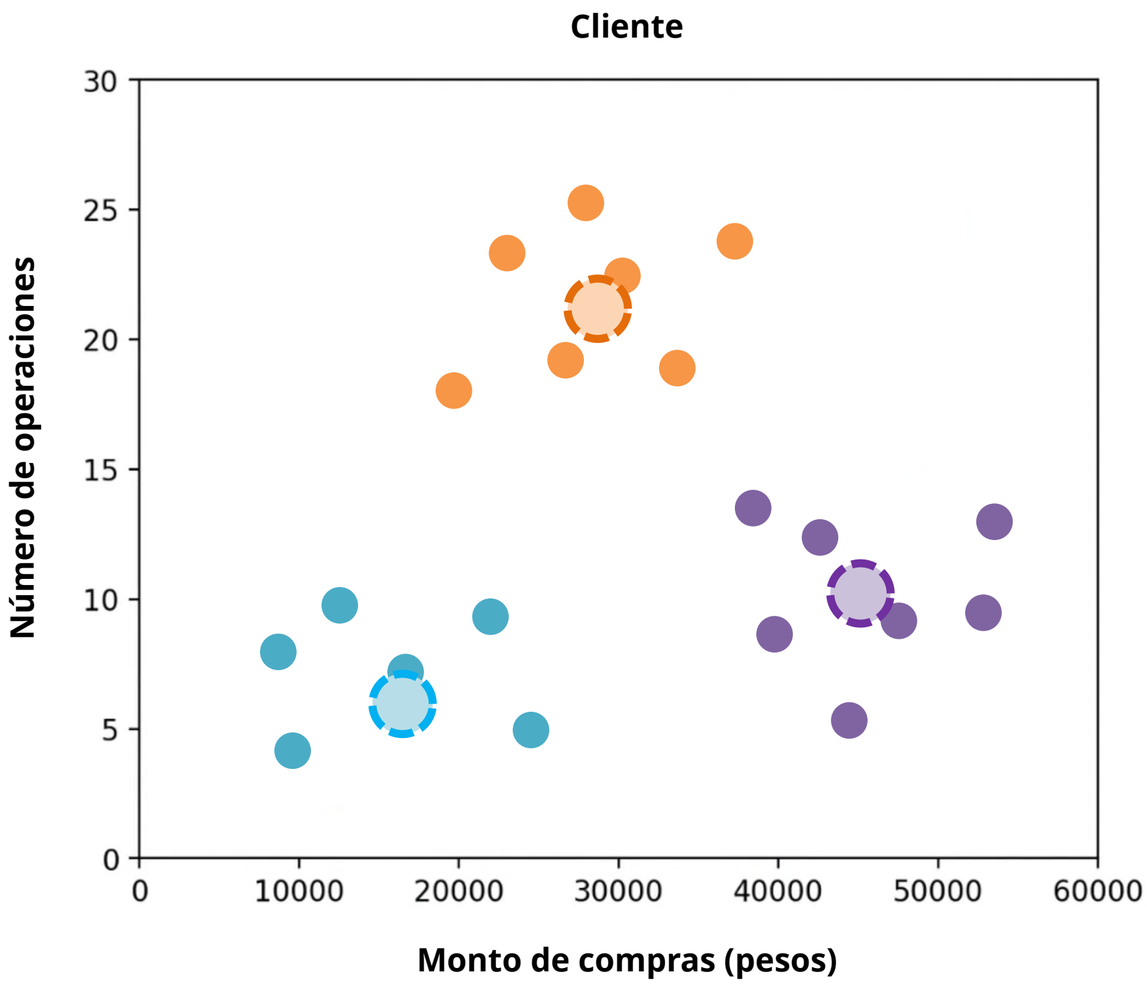

Etapa: Actualización
K = 3
Iteración = 2

ANÁHUAC PUEBLA

K-Means: Ejemplo (práctico)

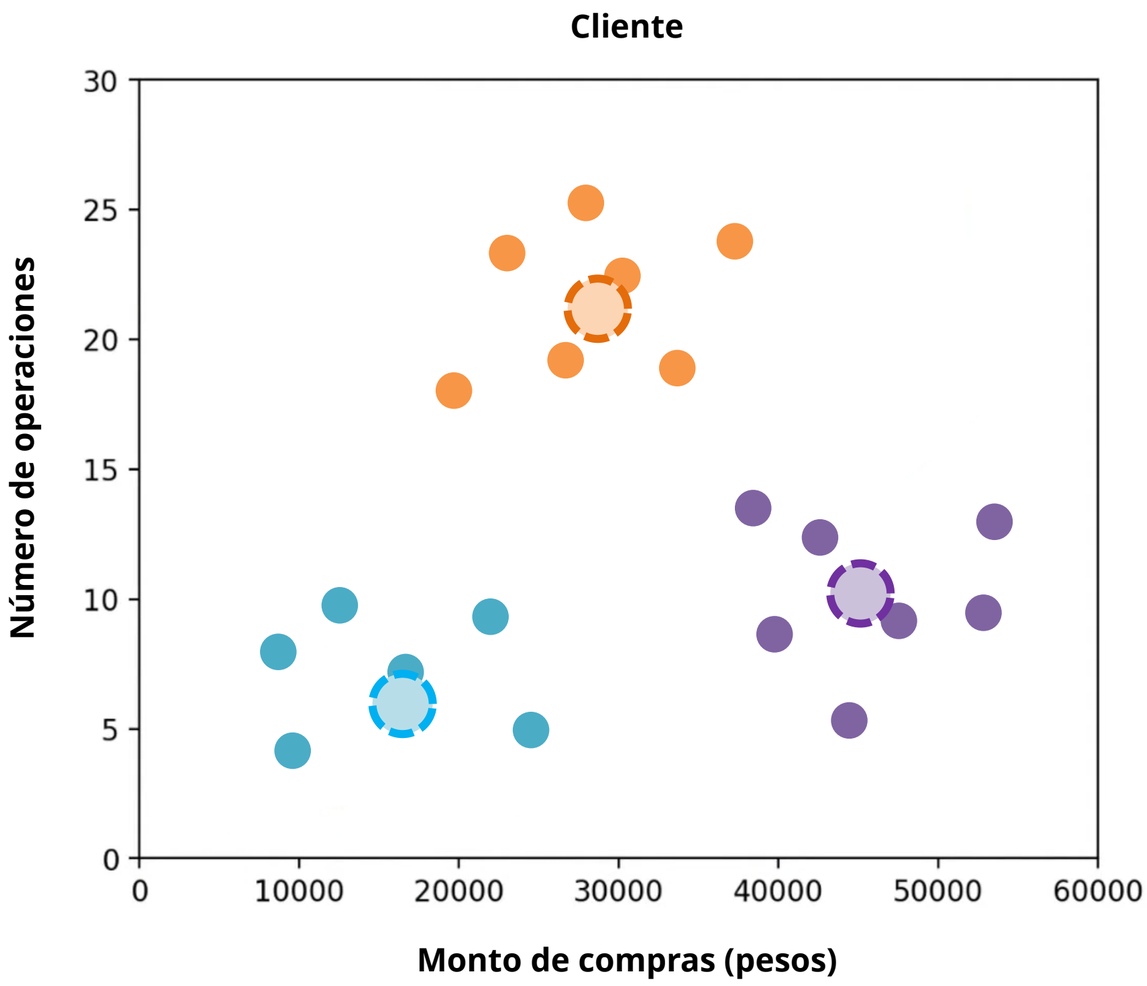

Etapa: Selección
K = 3
Iteración = 3
- Sin modificaciones -

ANÁHUAC PUEBLA

Referencias

- J. MacQueen (1967). “Some Methods for classification and Analysis of Multivariate Observations.” (artículo fundador que introduce K-Means).
- A. K. Jain, M. N. Murty, P. J. Flynn (1999). “Data Clustering: A Review.” ACM Computing Surveys, 31(3): 264–323. (revisión comprensiva de métodos de clustering).
- I. T. Jolliffe, J. Cadima (2016). “Principal component analysis: a review and recent developments.” Philosophical Transactions A (técnica de reducción de dimensionalidad útil para visualización).
- A. K. Jain (2010). “Data clustering: 50 years beyond K-Means.” Pattern Recognition Letters (visión histórica y crítica).
- Kavlakoglu, E., & Winland, V. (2025). ¿Qué es la agrupación en clústeres k-means? Recuperado de https://www.ibm.com/mx-es/think/topics/k-means-clustering

GRACIAS

ANÁHUAC
PUEBLA