ANÁHUAC

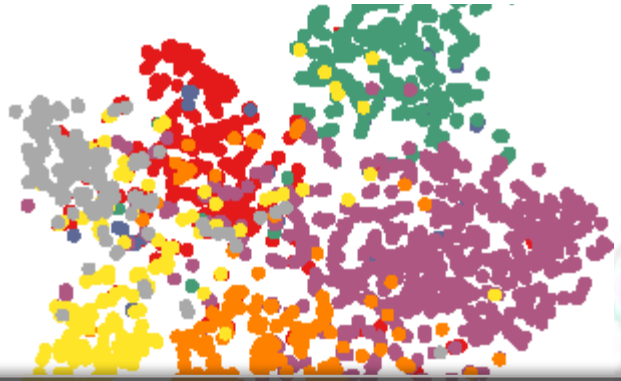

K- Vecinos Más Cercanos
KNN

ANÁHUAC

Técnicas Machine Learning

Aprendizaje Supervisado

…

- Árboles Decisión
- SVM
- Vecinos más cercanos KNN
- Regresión Lineal
- Regresión Logística
- Redes Neuronales
- Bayes
- Discriminantes de Fisher
- …

ANÁHUAC

K- Vecinos Más Cercanos K-NN (k-Nearest Neighbors)

Su principio fundamental consiste en que **las observaciones similares tienden a tener resultados similares**.

KNN

Variable Categórica

Problemas de Clasificación

Variable Continua

Problemas de Regresión

ANÁHUAC

K-Vecinos Más Cercanos

K Vecinos Más Cercanos (k-NN) es una técnica de aprendizaje supervisado utilizada para clasificación, cuyo objetivo es **predecir la clase o valor de una observación a partir de los *k* datos más cercanos**, medidos mediante una función de distancia.

ANÁHUAC

KNN

Dime con quién andas y te diré quién eres

El algoritmo KNN clasifica a un dato nuevo, de acuerdo con la clase de la mayoría de sus ***k*** vecinos más cercanos.

KNN

Clasificación de un nuevo objeto

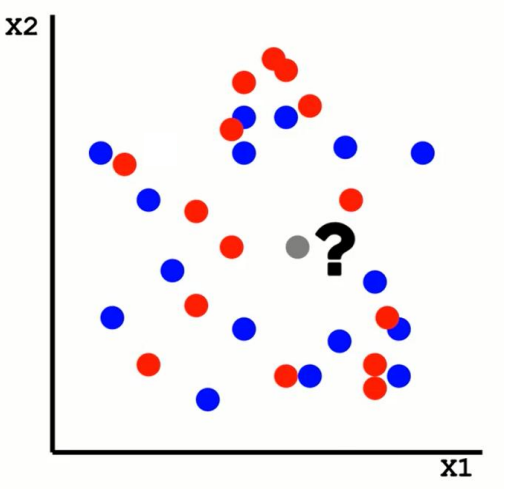

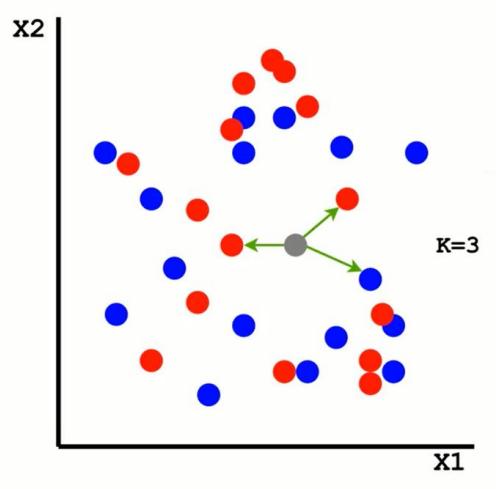

K Vecinos más próximos

x 2

x 1

Distancias mayormente usadas en KNN

- Euclidiana (Muy común en datos continuos)
- Manhattan (Menos sensible a valores extremos)

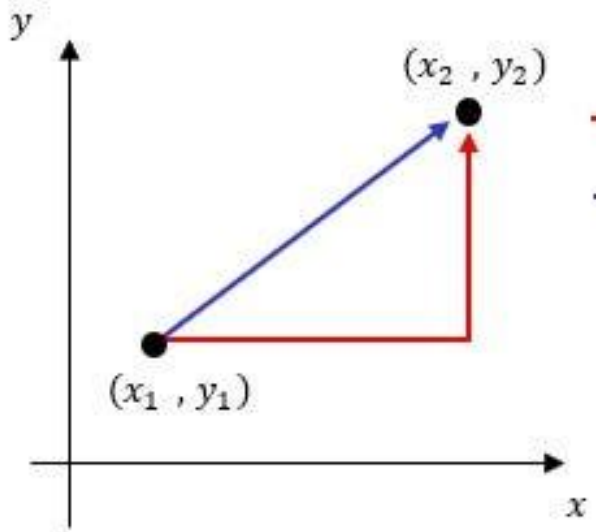

Manhattan Distance L^1

Euclidean Distance L^2

$$L^1 = |x_2 - x_1| + |y_2 - y_1|$$

$$L^2 = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

KNN

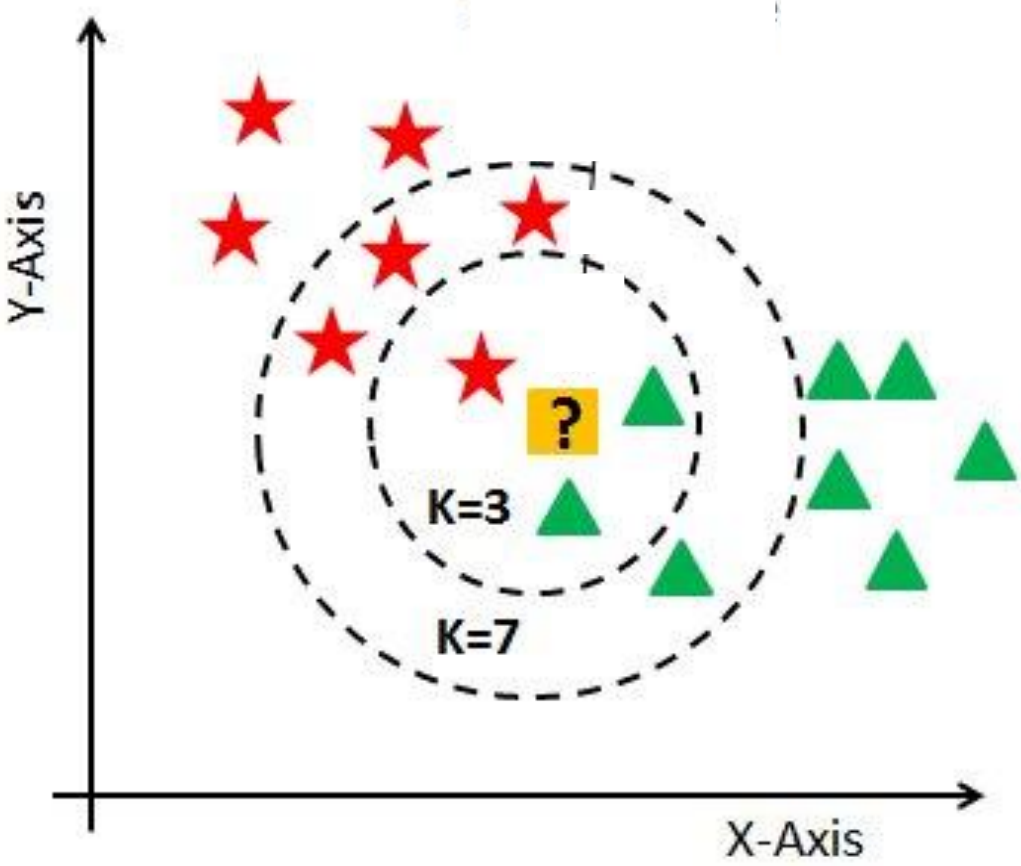

- Usar k impar
- Empezar con valore pequeños (entre 3 y 15)
- $k \approx \sqrt{n}$

KNN

Edad	Ingresos (miles /quincenal)	Sexo	Comprar_Producto
25	5	1	Sí
35	7	2	No
30	7	2	Sí
…	…	…	…
32	6	1	No
36	5	1	No

$$\sqrt{(25-31)^2+(5-6)^2+(1-1)^2}=6.082$$

$$\sqrt{(35-31)^2+(7-6)^2+(2-1)^2}=4.242$$

$$\sqrt{(30-31)^2+(7-6)^2+(2-1)^2}=1.732$$

$$\sqrt{(32-31)^2+(6-6)^2+(1-1)^2}=1.000$$

$$\sqrt{(36-31)^2+(5-6)^2+(1-1)^2}=5.099$$

31	6	1

¿Comprará el producto?

KNN

Edad	Ingresos (miles /quincenal)	Sexo	Comprar_Producto
25	5	1	Sí
35	7	2	No
30	7	2	Sí
…	…	…	…
32	6	1	No
36	5	1	No

$$\sqrt{(25-31)^2+(5-6)^2+(1-1)^2}=6.082$$

$$\sqrt{(35-31)^2+(7-6)^2+(2-1)^2}=\boxed{4.242}$$

$$\sqrt{(30-31)^2+(7-6)^2+(2-1)^2}=\boxed{1.732}$$

$$\sqrt{(32-31)^2+(6-6)^2+(1-1)^2}=\boxed{1.000}$$

$$\sqrt{(36-31)^2+(5-6)^2+(1-1)^2}=5.099$$

31	6	1

¿Comprará el producto? **No**

ANÁHUAC

KNN

Ventajas

- Fácil de implementar
- Fácil de modificar (solo 2 parámetros K y métrica de distancia)
- No construye un modelo previo; utiliza directamente los datos de entrenamiento (aprendizaje perezoso - lazy learning).
- Funciona bien cuando las clases no son linealmente separables.

Desventajas

- Computacionalmente intensivo para datasets grandes. Hay que calcular la distancia del punto nuevo a todos los puntos (o muchos)
- Alta dependencia de la elección de k. Un k pequeño puede producir sobreajuste y un k grande puede suavisar mucho la decisión
- Sensible a la escala de las variables y a bases de datos desbalanceadas
- No funciona bien con muchas variables predictoras categóricas

KNN

k-NN se recomienda en problemas con datos numéricos bien escalados, tamaño moderado y relaciones no lineales, especialmente como modelo exploratorio o de referencia.

Train-Test

- El train y el test se seleccionan de manera aleatoria.

Con un solo split:

- El resultado puede depender **del azar**
- Pudo tocarte un test “fácil” o “difícil”
- El modelo puede parecer mejor o peor de lo que realmente es

Validación Cruzada

La validación cruzada es una técnica para evaluar qué tan estable y confiable es un modelo, entrenándolo y evaluándolo varias veces con distintas particiones de los datos.

ANÁHUAC

Ejemplo Validación Cruzada 5-Folds

Supón que tienes los datos divididos en 5 bloques:

- Fold 1
- Fold 2
- Fold 3
- Fold 4
- Fold 5

El proceso sería:

Iteración	Entrenamiento	Validación
1	2–3–4–5	1
2	1–3–4–5	2
3	1–2–4–5	3
4	1–2–3–5	4
5	1–2–3–4	5

Validación Cruzada-Test externo

Idea

- Primero evalúo estabilidad (CV).
- Luego evalúo desempeño final (test externo).

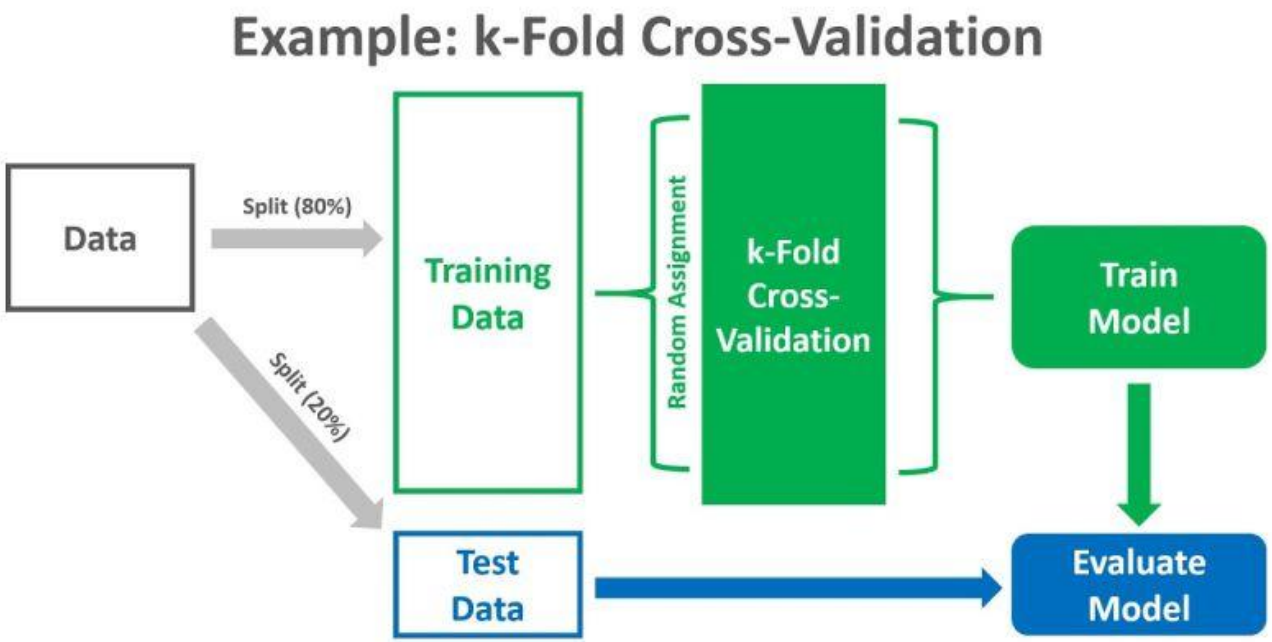

Métricas Clasificación

Accuracy (Exactitud):

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

		Clase predicha	
		Positiva	**Negativa**
Clase real	**Positiva**	TP	FN
	Negativa	FP	TN

Precision (Precisión): "¿Qué tan confiable es mi SÍ?"

$$\text{Precision} = \frac{TP}{TP + FP}$$

De todos los que el modelo dijo "Sí contrata", ¿cuántos de verdad contratan?

Recall (Sensibilidad): "¿Cuántos Sí reales logré encontrar?"

$$\text{Recall} = \frac{TP}{TP + FN}$$

De todos los que **sí contratan en la realidad**, ¿a cuántos detecté?

Métricas Clasificación

F1 Balance entre precisión y recall: Solo es alto si **ambas** (precision y recall) son altas y penaliza cuando una es muy baja

$$\mathrm{F1} = 2 \cdot \frac{\mathrm{Precision} \cdot \mathrm{Recall}}{\mathrm{Precision} + \mathrm{Recall}}$$

Macro average: Calcula la métrica por clase y luego hace un promedio simple

$$\mathrm{Precision}_{macro} = \frac{1}{K} \sum_{k=1}^{K} \mathrm{Precision}_k$$

Weighted average: Calcula la métrica por clase y luego pondera según los datos por clase

$$\mathrm{Precision}_{weighted} = \sum_{k=1}^{K} \frac{n_k}{N} \cdot \mathrm{Precision}_k$$

n_k = support de la clase k

N = total de muestras

ANÁHUAC

Métricas

Situación	Métrica recomendada
Clases balanceadas	Accuracy
Clases desbalanceadas	F1
No perder positivos	Recall
Evitar falsas alarmas	Precisión
Evaluación general	F1

Buenas prácticas

- Escalar datos numéricos
- Utilizar Validación Cruzada
- Estratificación
- Usar métricas adecuadas

ANÁHUAC

¡Momento de ir a Programar!