ANÁHUAC PUEBLA

Asignatura:_Machine Learning

Algoritmos de agrupamiento:
Mean Shift

Presentado por:

Paulo Daniel Vázquez Mora

Objetivo general

- Conocer el algoritmo de agrupamiento por desplazamiento de la media o promedio.
- Identificar las ventajas de este algoritmo.
- Explorar aplicaciones prácticas del desplazamiento de la media.
- Aprender la implementación paso a paso en Python.
- Comparar el algoritmo con K-means para entender las diferencias principales.

ANÁHUAC PUEBLA

Introducción

Como ya se ha establecido, el clustering identifica estructuras/patrones ocultas/os en los datos para ayudar en la toma de decisiones informadas. Algunas de sus aplicaciones más comunes es la segmentación de clientes, la segmentación de imágenes y el análisis de redes sociales.

A su vez, el clustering se puede dar en dos escenarios: **paramétricos** y **no paramétricos**. El algoritmo de agrupación por desplazamiento de la media o promedio es no paramétrico.

ANÁHUAC PUEBLA

¿Qué es el Mean Shift (MS)?

MS es un algoritmo que identifica clústeres encontrando los picos en la densidad de datos, desplazando iterativamente los centros hacia áreas más densas. Así, agrupa puntos según los modos de distribución, permitiendo detectar clústeres de formas variadas sin asumir un modelo fijo.

ANÁHUAC PUEBLA

¿Qué es el Mean Shift (MS)?

MS cumple con cuatro pasos:

1. Inicialización

Comienza por considerar cada punto de datos como un candidato potencial para el centro del clúster.

2. Densidad

Para cada punto de datos, se define una ventana a su alrededor, llamada radio, y luego se calcula la media de esos puntos de datos dentro de este radio.

3. Desplazamiento

Desplaza cada punto a su posición media. Este paso mueve el punto hacia la región de mayor densidad.

4. Convergencia

Repetir los pasos 2 y 3 iterativamente hasta la convergencia, es decir, cuando el desplazamiento sea menor que un umbral predefinido.

ANÁHUAC PUEBLA

Aplicaciones: Segmentación de imágenes

MS encuentra agrupaciones (cuyo número se desconoce) desplazando iterativamente los puntos de datos hacia las regiones más densas del espacio de características. Esto lo hace especialmente útil para reconocimiento de objetos, donde puede segmentar imágenes según la intensidad y el color de los píxeles.

(a) Original Image

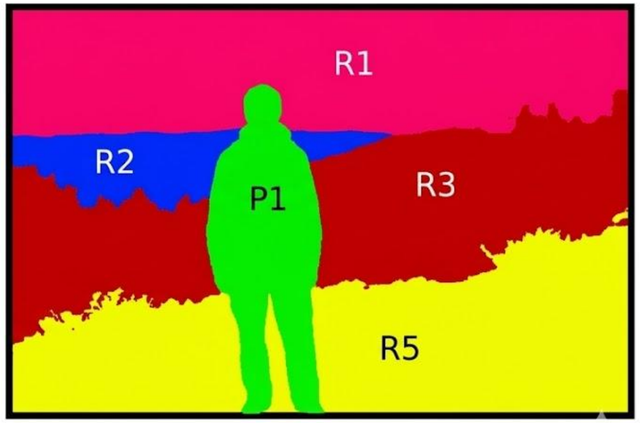

(b) Segmented Image

ANÁHUAC PUEBLA

Aplicaciones: Imagenología médica

En casos como imágenes con ruido y poca luz, el algoritmo proporciona una segmentación más natural y precisa, esencial en aplicaciones como la imagenología médica para detectar tipos de tejido anormal o en visión artificial para la detección fiable de objetos.

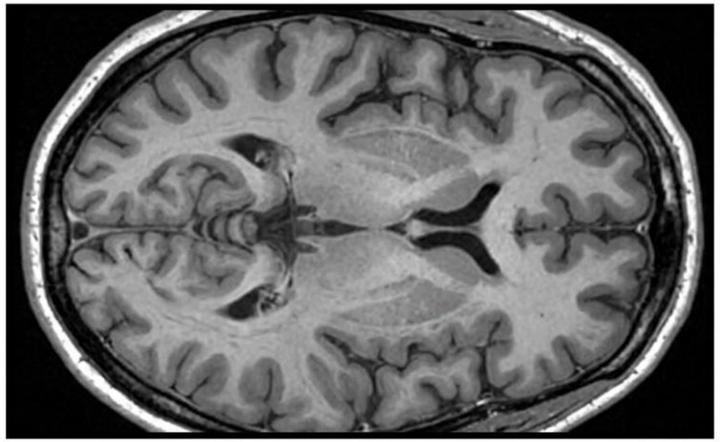

(a) Original Image

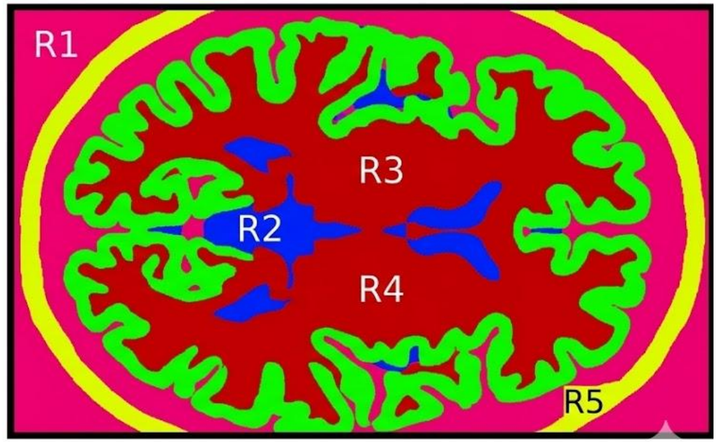

(b) Segmented Image

ANÁHUAC PUEBLA

Aplicaciones: Seguimiento de objetos

Por otro lado, Mean Shift se utiliza con frecuencia en el seguimiento de objetos en secuencias de vídeo. Su capacidad para identificar y seguir dinámicamente los objetos a medida que se mueven entre fotogramas la hace muy eficaz para aplicaciones de seguimiento en tiempo real.

(a) (b) (c) (d)

ANÁHUAC PUEBLA

Aplicaciones: Segmentación de clientes

ANÁHUAC PUEBLA

Para las organizaciones, es crucial identificar segmentos de clientes sin limitarse a un número fijo y considerando comportamientos atípicos. Mean Shift analiza patrones de compra, comportamiento y datos demográficos para detectar agrupaciones naturales de cualquier tamaño, facilitando estrategias de marketing personalizadas que mejoran la participación y retención de clientes.

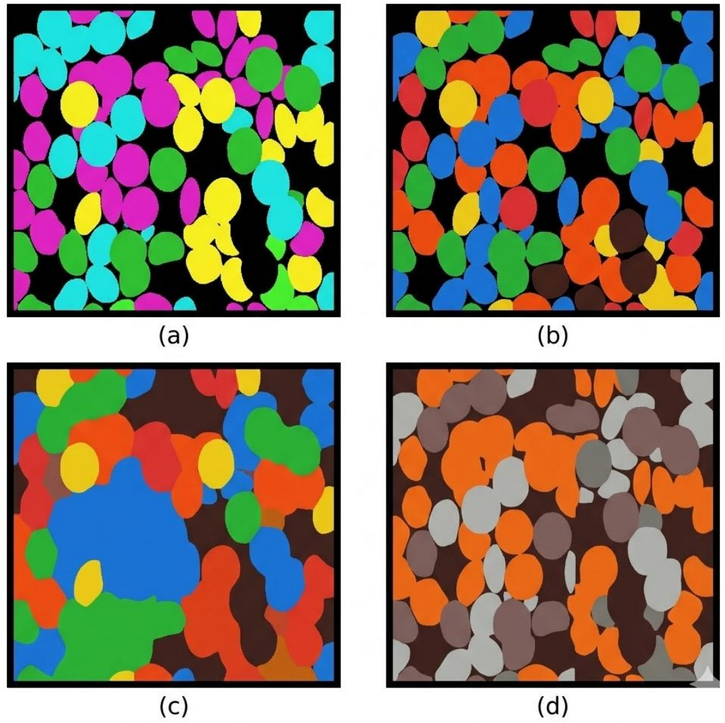

¿Cómo funciona MS?

MS se apoya en la función de densidad de probabilidad de una variable aleatoria para identificar áreas con mayor densidad de datos en cada iteración. La fórmula de KDE (densidad del kernel) es:

$$\hat{f}(x) = \frac{1}{nh^d} \sum_{i=1}^{n} k\left(\frac{x - x_i}{h}\right)$$

Donde ***h*** es un parámetro de ancho de banda y el kernel suele ser gaussiano. La función kernel ***k*** suaviza la contribución de cada punto de datos, asegurando que los puntos más cercanos a ***x*** tengan una mayor influencia en la estimación de la densidad.

ANÁHUAC PUEBLA

Selección del ancho de banda

El parámetro de ***ancho de banda h (band-width)*** determina el tamaño de la vecindad alrededor de cada punto de datos, lo que influye directamente en los resultados de la agrupación. Los siguientes métodos son usados para dicho propósito:

1. Regla de Scott
2. Regla de Silverman
3. Validación cruzada
4. Conocimiento experto
5. Ancho de banda adaptativo

ANÁHUAC PUEBLA

1. Regla de Scott

La regla de Scott es un enfoque heurístico que proporciona una regla general para la selección del ancho de banda. Equilibra el sesgo y la varianza en la estimación de la densidad, lo que la convierte en un buen punto de partida para numerosas aplicaciones.

$$h = n^{-\frac{1}{d+4}}$$

Donde:

- ***n*** es el número de puntos de datos.
- ***d*** es el número de dimensiones en el conjunto de datos.

ANÁHUAC PUEBLA

2. Regla de Silverman

Similar a la regla de Scott, la regla de Silverman ofrece otro enfoque heurístico para la selección del ancho de banda, particularmente útil para distribuciones unimodales.

$$h = \left(\frac{4}{d+2}\right)^{\frac{1}{d+4}} n^{-\frac{1}{d+4}}$$

ANÁHUAC PUEBLA

3. Validación cruzada

Para determinar el ancho de banda óptimo que minimice el error y mejore el agrupamiento, se recomienda:

1. **Dividir** los datos en conjuntos de entrenamiento y validación.
2. **Aplicar** la agrupación por desplazamiento medio con distintos anchos de banda en el conjunto de entrenamiento.
3. **Evaluar** el desempeño de cada ancho de banda en el conjunto de validación.
4. **Seleccionar** el ancho de banda que presente el menor error.

ANÁHUAC PUEBLA

4. Conocimiento experto

El conocimiento experto puede proporcionar información valiosa para seleccionar el ancho de banda adecuado, especialmente en aplicaciones específicas, como el procesamiento de imágenes. Un experto podría comprender la escala típica de las características de la imagen para elegir el rango de ancho de banda óptimo y luego ajustarlo mediante pruebas empíricas.

ANÁHUAC PUEBLA

5. Ancho de banda adaptativo

El ancho de banda adaptativo es útil para conjuntos de datos con densidades variables. Aplica diferentes anchos de banda para distintas regiones de los datos. Comienza con una estimación global del ancho de banda y luego la ajusta localmente en función de la densidad de los puntos de datos en esa región.

ANÁHUAC PUEBLA

Vector de desplazamiento medio

ANÁHUAC PUEBLA

El vector de desplazamiento medio representa la magnitud y la dirección del movimiento necesario para desplazar la estimación del centro del grupo desde áreas de menor densidad a regiones de mayor densidad.

Para un punto de datos xi , el vector de desplazamiento medio m(xi) se calcula como:

$$m(xi) = \frac{\sum_{x_j \in N(x_i)} K(x_j - x_i) x_j}{\sum_{x_j \in N(x_i)} K(x_j - x_i)} - x_i$$

donde N(xi) denota la vecindad alrededor de xi definida por el ancho de banda.

Convergencia

El algoritmo MS converge cuando los centros de los conglomerados dejan de moverse más allá de un umbral y se identifican las modas de la función de densidad que forman los grupos. Este proceso incluye:

1. **Calcular** el vector de desplazamiento medio para cada punto.
2. **Mover** cada punto hacia la media de su vecindad.
3. **Verificar** si los cambios son menores que un umbral establecido.

Esta convergencia indica que los puntos se estabilizan alrededor de los máximos locales de la densidad, que actúan como centroides.

ANÁHUAC PUEBLA

Referencias

- J. MacQueen (1967). “Some Methods for classification and Analysis of Multivariate Observations.” (artículo fundador que introduce K-Means).
- A. K. Jain, M. N. Murty, P. J. Flynn (1999). “Data Clustering: A Review.” ACM Computing Surveys, 31(3): 264–323. (revisión comprensiva de métodos de clustering).
- I. T. Jolliffe, J. Cadima (2016). “Principal component analysis: a review and recent developments.” Philosophical Transactions A (técnica de reducción de dimensionalidad útil para visualización).
- A. K. Jain (2010). “Data clustering: 50 years beyond K-Means.” Pattern Recognition Letters (visión histórica y crítica).
- Kavlakoglu, E., & Winland, V. (2025). ¿Qué es la agrupación en clústeres k-means? Recuperado de https://www.ibm.com/mx-es/think/topics/k-means-clustering

GRACIAS

ANÁHUAC
PUEBLA