ANÁHUAC

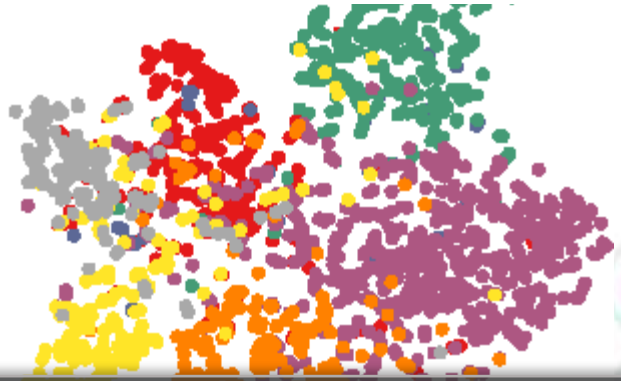

Máquinas de Vectores de Soporte

ANÁHUAC

Técnicas Machine Learning

Aprendizaje Supervisado

…

- Árboles Decisión
- SVM
- Vecinos más cercanos KNN
- Regresión Lineal
- Regresión Logística
- Redes Neuronales
- Bayes
- Discriminantes de Fisher
- …

ANÁHUAC

Máquinas de Vectores de Soporte

El objetivo es crear un modelo que clasifica o predice una variable de destino en función de diversas variables de entrada.

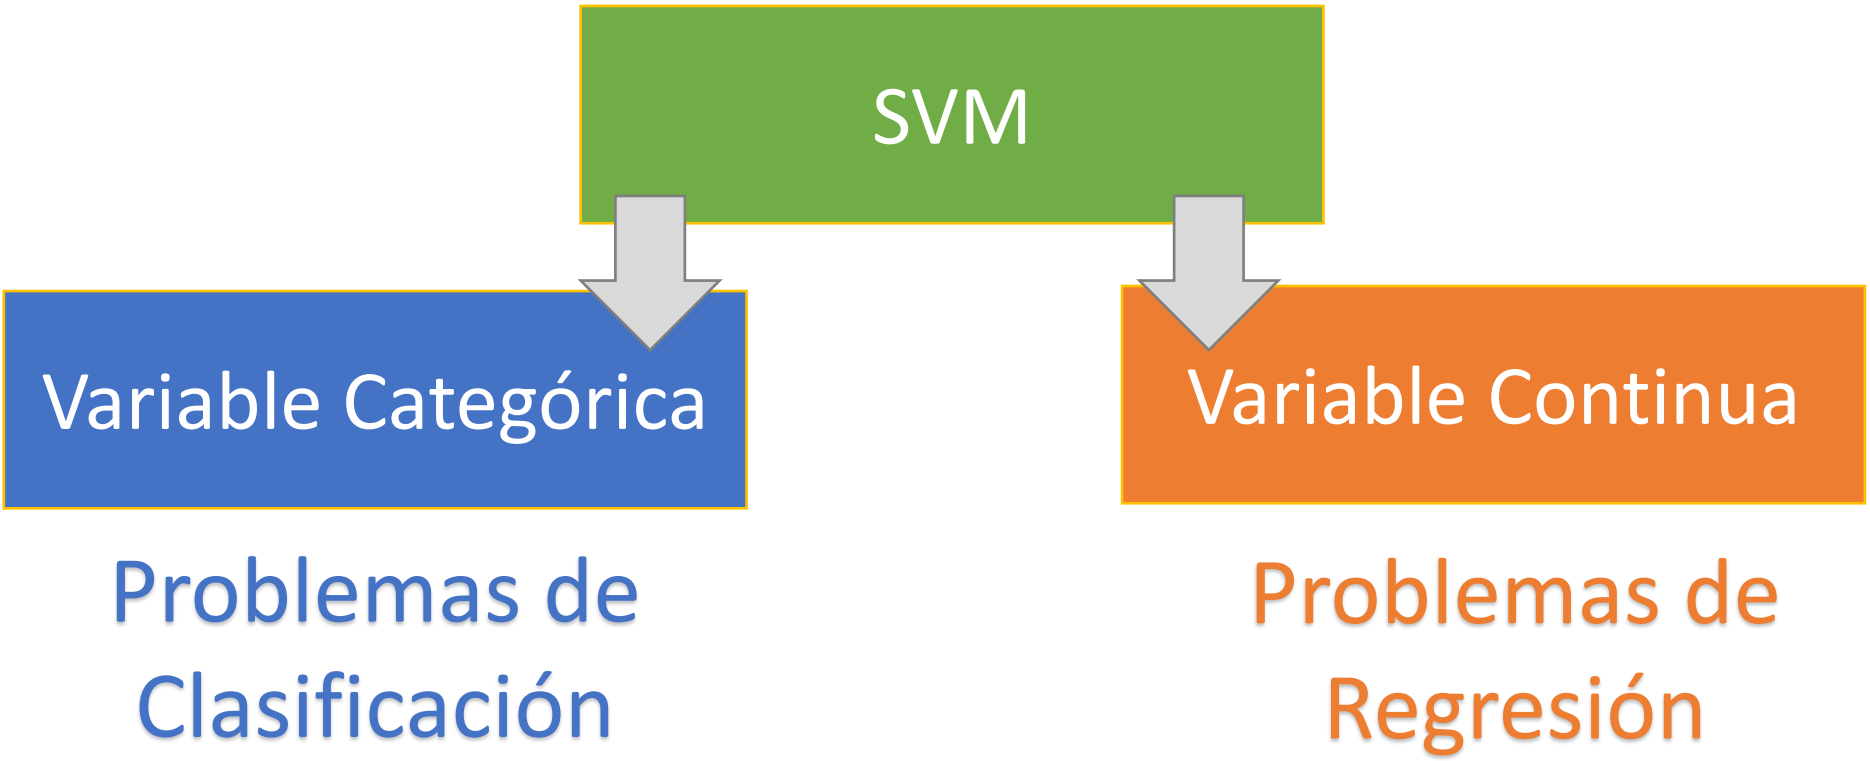

ANÁHUAC

Máquinas de Vectores de Soporte

SVM es una técnica de *aprendizaje supervisado* utilizada para **clasificación**, cuyo objetivo es encontrar un **hiperplano óptimo** que separe los datos de distintas clases **maximizando el margen** entre ellas.

ANÁHUAC

Máquinas de Vectores de Soporte

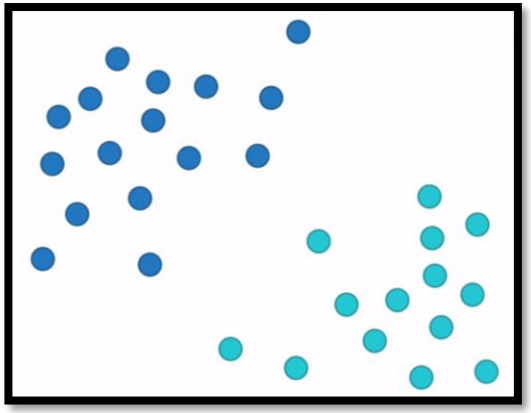

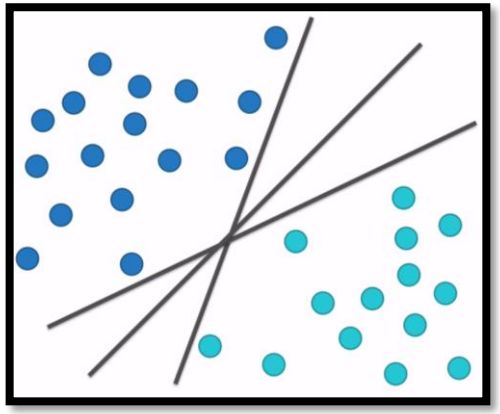

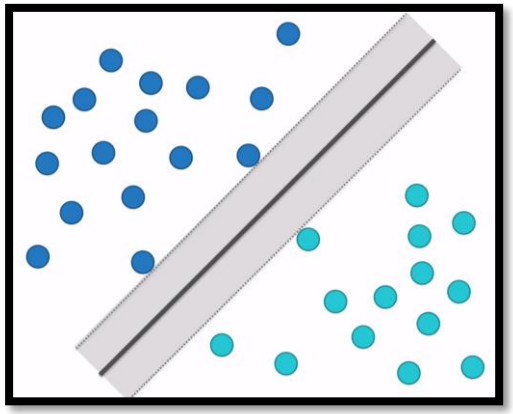

SVM no solo quiere separar,
quiere **maximizar la distancia entre clases**. Entre más ancho el margen: mayor robustez

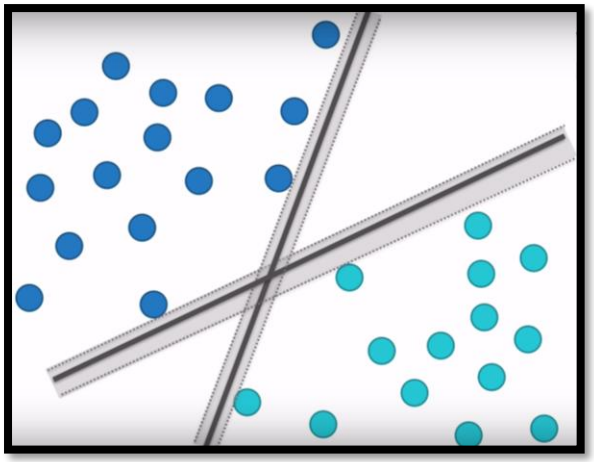

No todos los separadores son igual de buenos.

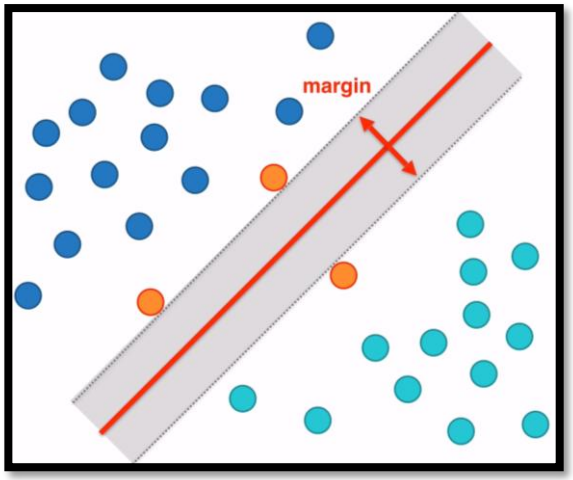

Solo los puntos más cercanos al margen definen el modelo. Máquinas de soporte de vectores

Parámetro C

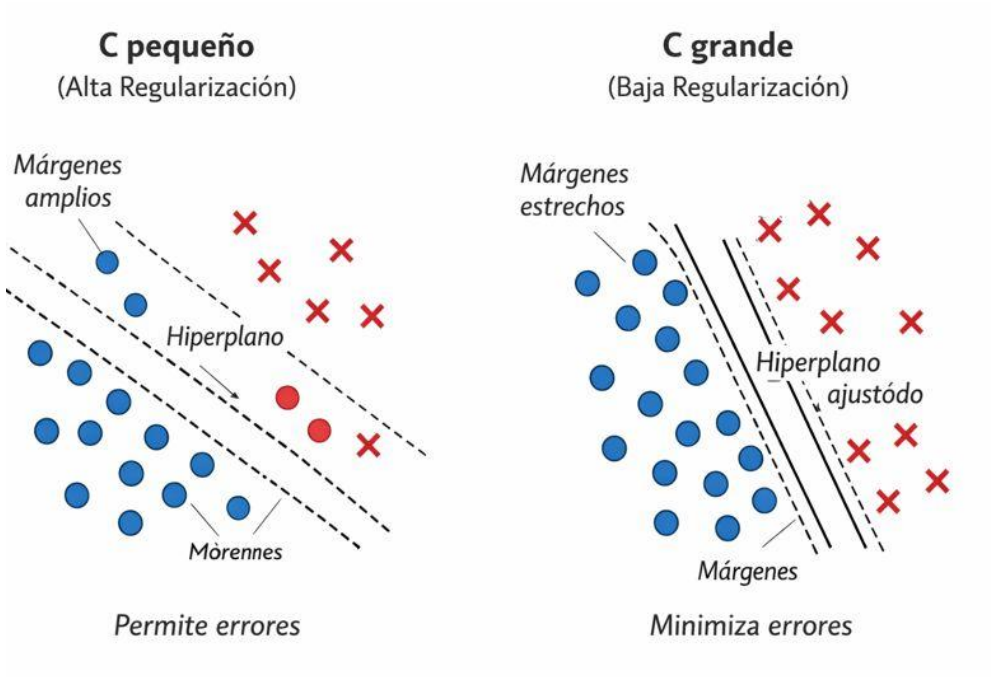

C controla que tan tolerante es el modelo a equivocarse

C pequeño

Permite errores, prefiere margen más grande, sub-ajuste (underfitting –modelo muy general y simple)

C grande

Penaliza mucho los errores, prefiere margen más pequeños, sobreajuste (overfitting –modelo muy específico para datos de entrenamiento)

ANÁHUAC

Parámetro Kernel

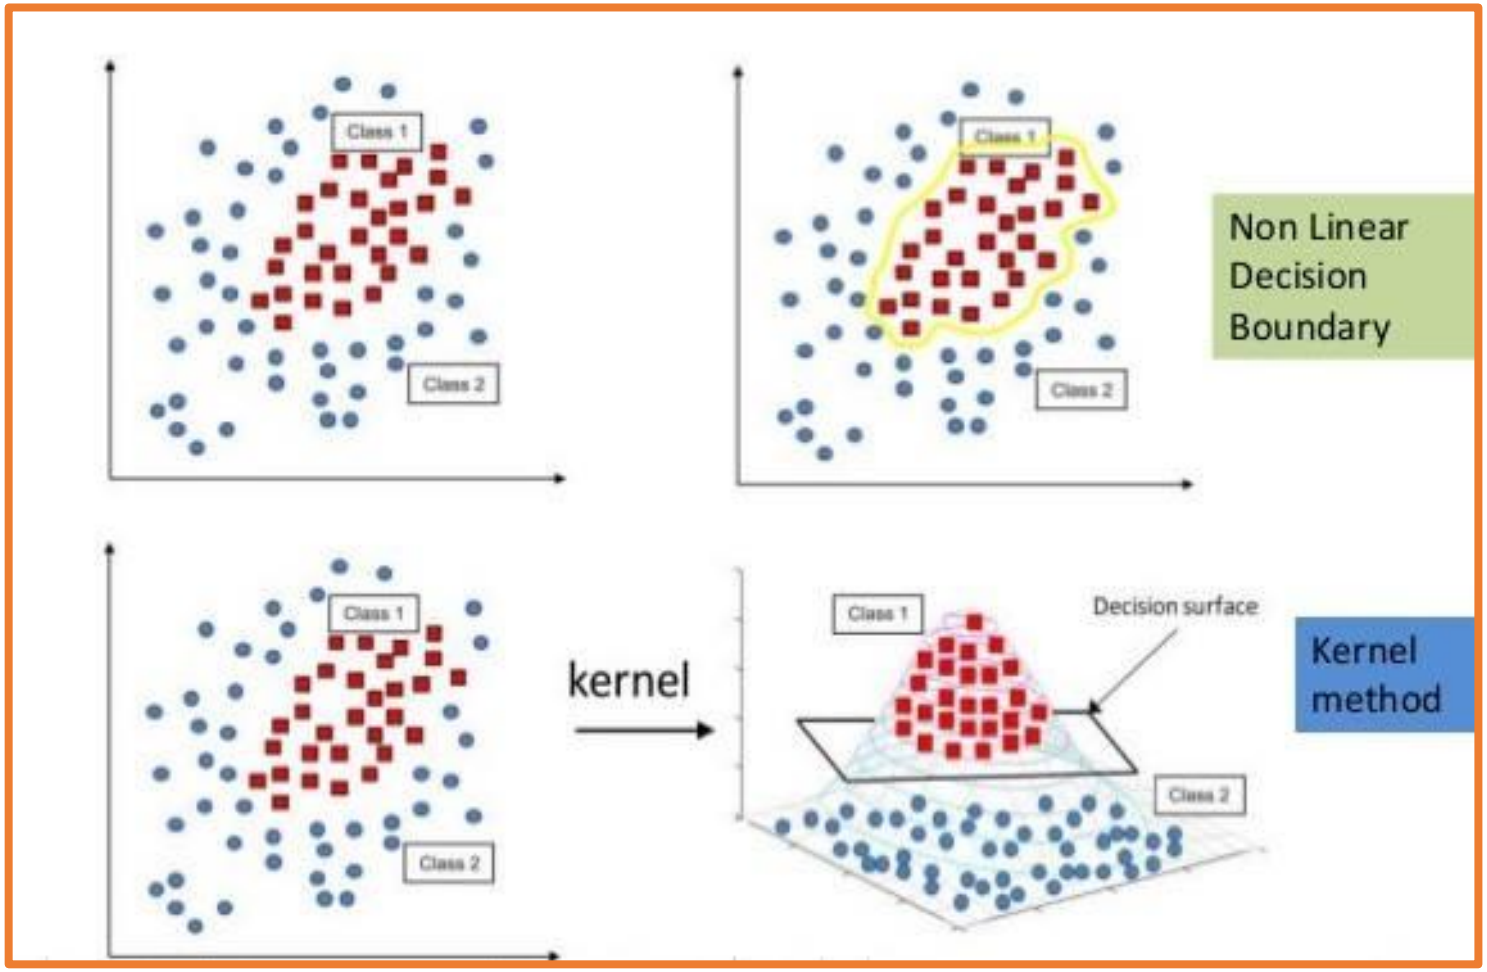

Principales Kernels: Lineal, RBF, etc.

Parámetro Gamma

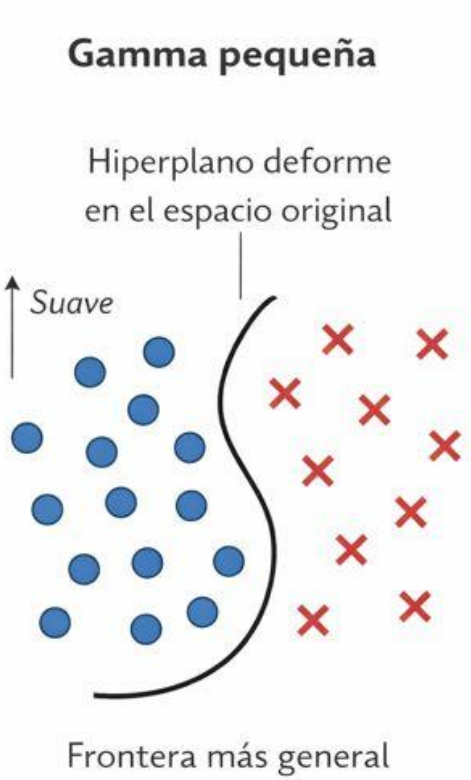

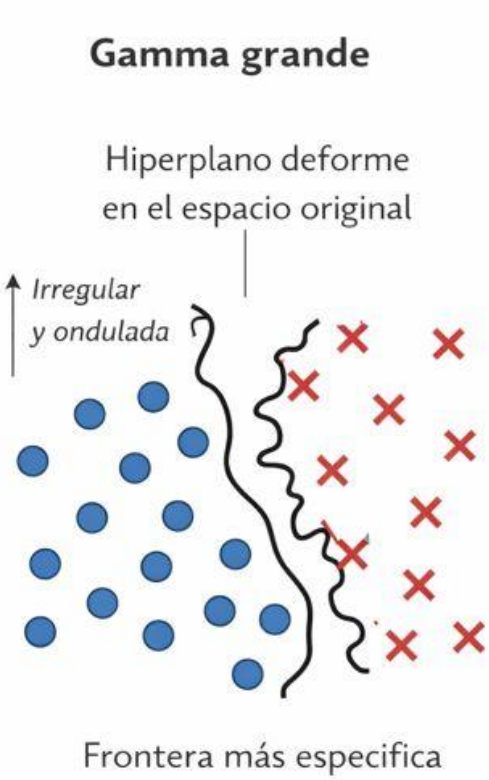

Gamma decide que tan ondulada se permite la frontera

Gamma pequeño

La frontera es suave, los vectores influyen desde lejos (0.001)

Gamma grande

La frontera es ondulada, los vectores influyen desde cerca (10)

ANÁHUAC

Máquinas de Vectores de Soporte

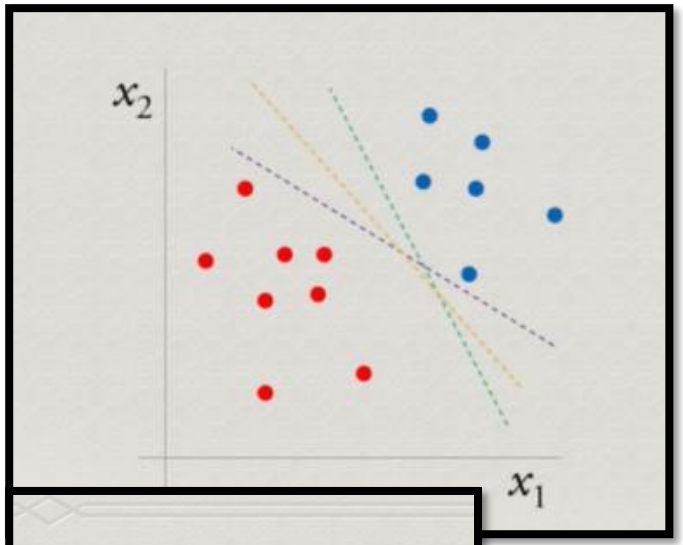

$$x^T w + b = 0$$

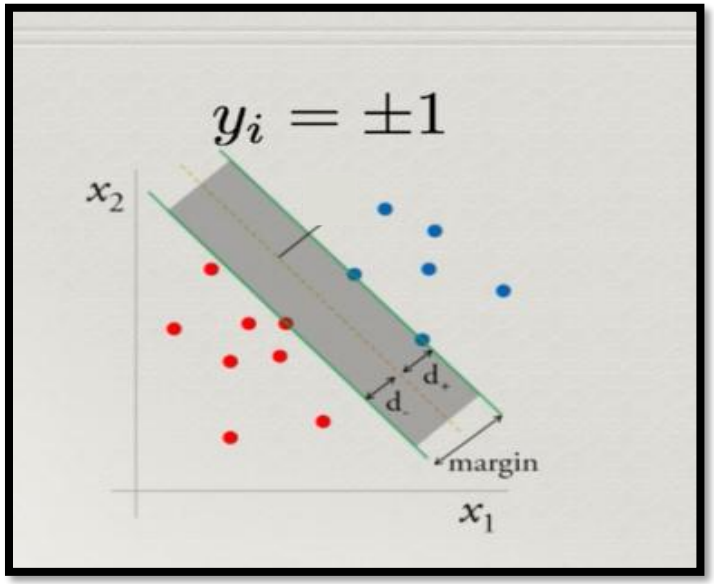

ANÁHUAC

Escalamiento de Datos

Antes de aplicar SVM, los datos numéricos deben ser escalados.

Ingreso: 1,200,000

Edad: 35

Probabilidad: 0.8

¿Por qué?

- SVM se basa en distancias y productos **punto**
- El margen depende de la magnitud de las variables
- Variables con escala grande **dominan la solución**
- El hiperplano se **distorsiona** si las escalas son muy distintas

ANÁHUAC

Escalamiento de Datos

¿Cómo lo escalamos?

Estandarización. Es el escalado de los atributos de tal manera que su media sea 0 y su desviación estándar se convierta en 1. Haciendo que las variables sean comparables en escala.

$$\boxed{z = \frac{x - \mu}{\sigma}}$$

Escalamiento de Datos

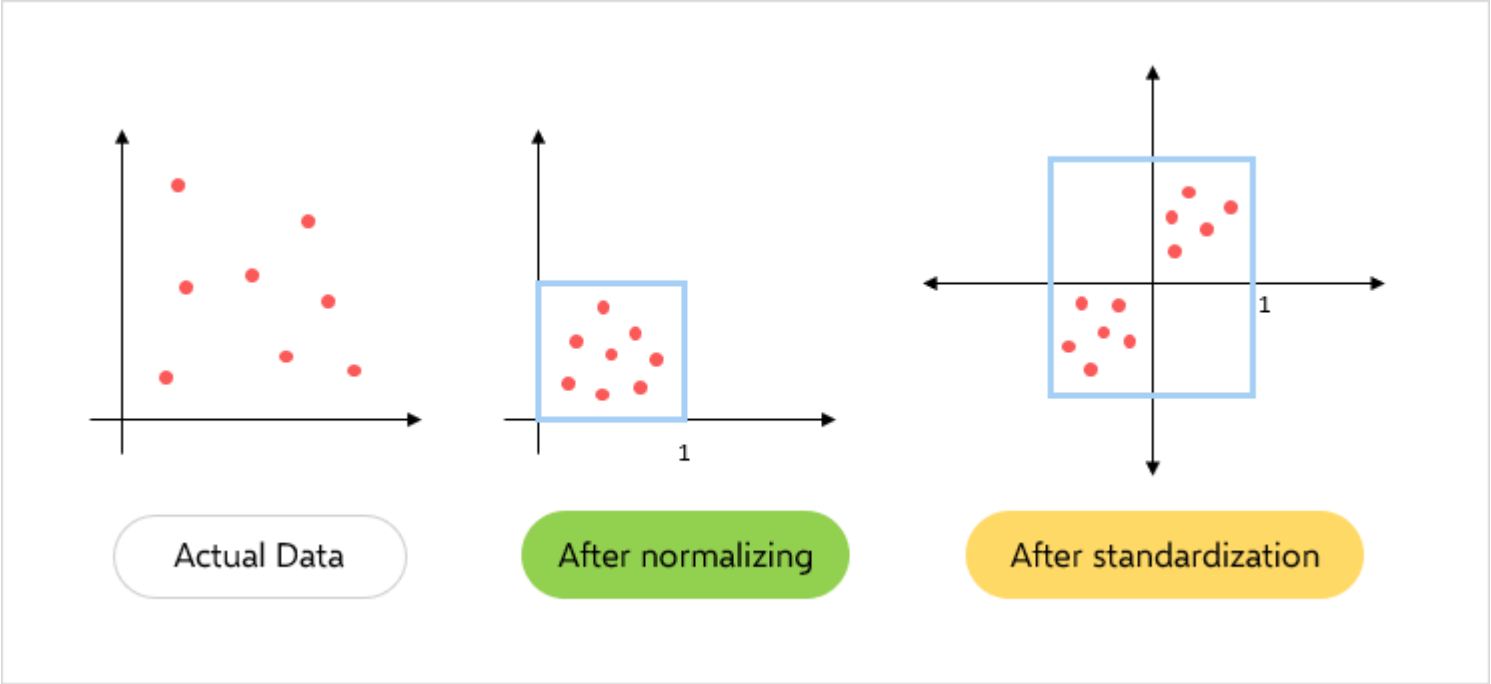

ANÁHUAC

Estratificación

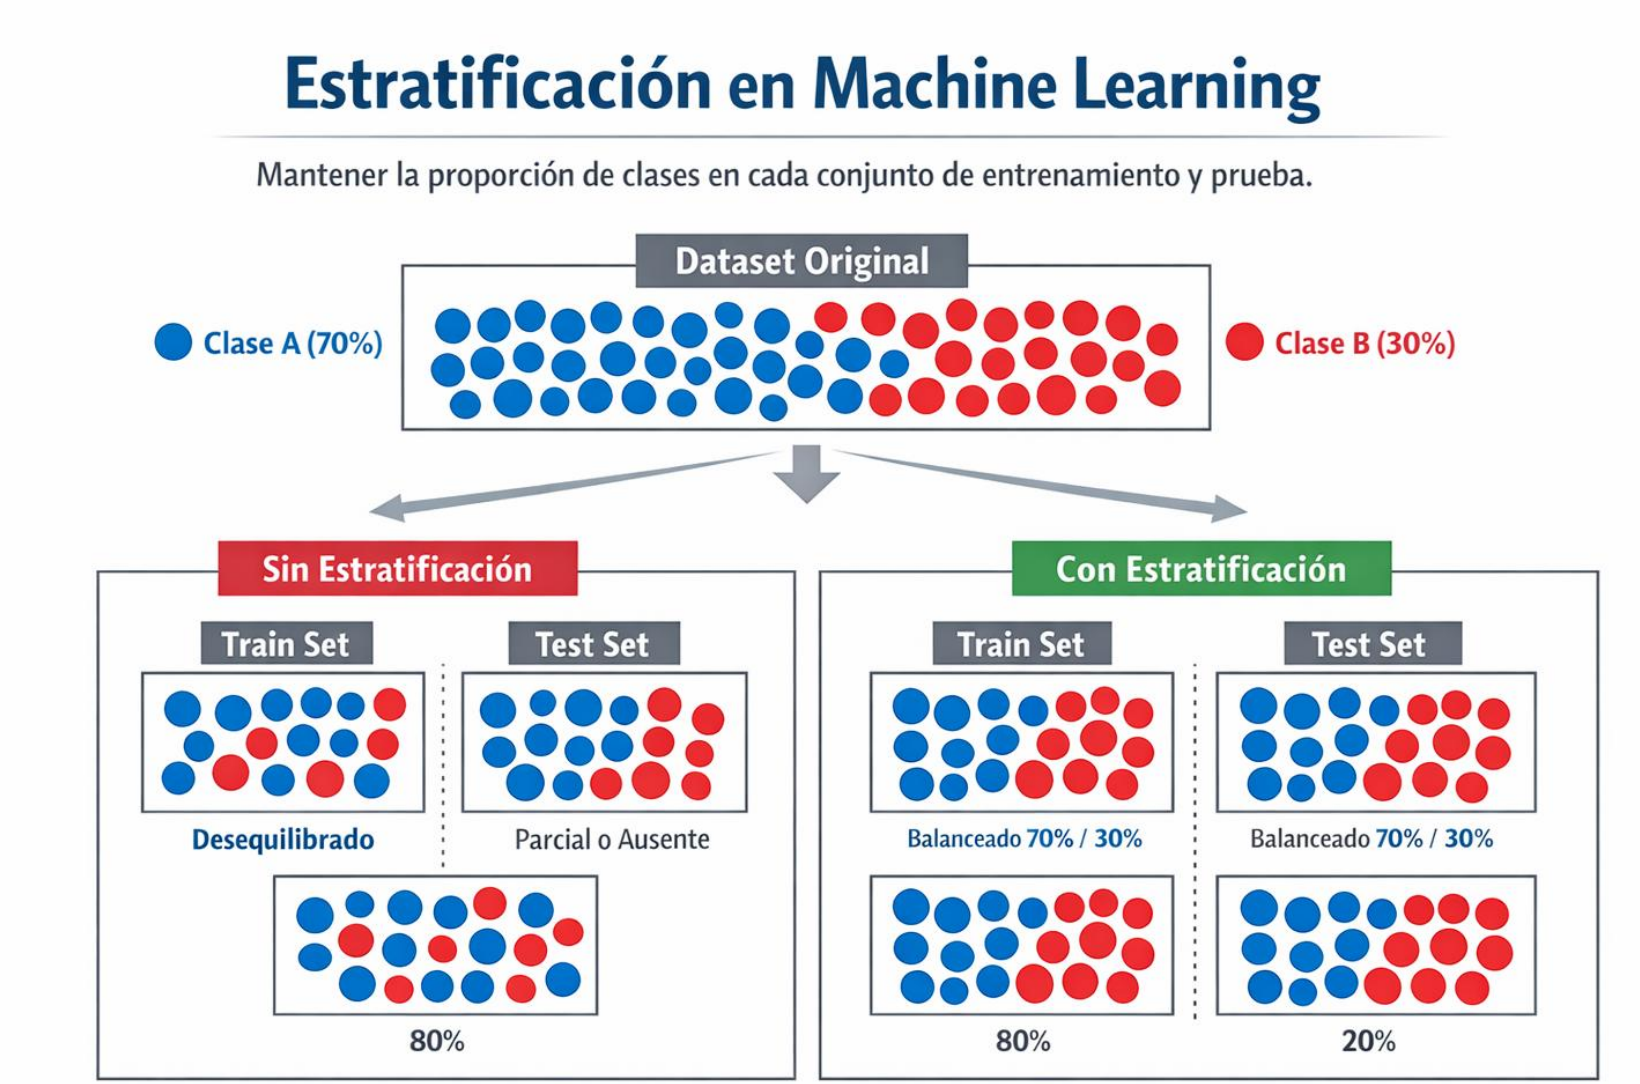

Métricas Clasificación

Accuracy (Exactitud):

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

		Clase predicha	
		Positiva	**Negativa**
Clase real	**Positiva**	TP	FN
	Negativa	FP	TN

Precision (Precisión): "¿Qué tan confiable es mi SÍ?"

$$\text{Precision} = \frac{TP}{TP + FP}$$

De todos los que el modelo dijo "Sí contrata", ¿cuántos de verdad contratan?

Recall (Sensibilidad): "¿Cuántos Sí reales logré encontrar?"

$$\text{Recall} = \frac{TP}{TP + FN}$$

De todos los que **sí contratan en la realidad**, ¿a cuántos detecté?

Métricas Clasificación

F1 Balance entre precisión y recall: Solo es alto si **ambas** (precision y recall) son altas y penaliza cuando una es muy baja

$$\mathrm{F1} = 2 \cdot \frac{\mathrm{Precision} \cdot \mathrm{Recall}}{\mathrm{Precision} + \mathrm{Recall}}$$

Macro average: Calcula la métrica por clase y luego hace un promedio simple

$$\mathrm{Precision}_{macro} = \frac{1}{K} \sum_{k=1}^{K} \mathrm{Precision}_k$$

Weighted average: Calcula la métrica por clase y luego pondera según los datos por clase

$$\mathrm{Precision}_{weighted} = \sum_{k=1}^{K} \frac{n_k}{N} \cdot \mathrm{Precision}_k$$

n_k = support de la clase k

N = total de muestras

Buenas prácticas

- Estratificar train / test
- Escalar datos numéricos
- Usar métricas adecuadas

En árboles, el escalamiento no es necesario; en SVM, sí.

ANÁHUAC

¡Momento de ir a Programar!